LAPORAN PRAKTIKUM PEMBELAJARAN MESIN
TUGAS PERTEMUAN 11 - REGRESI

"Prediksi Harga Penutupan ETF USO Menggunakan AdaBoost Regressor dan Gradient Boosting Regressor"



Dosen Pengampu :
Purbandini, S.Si., M.Kom.

Oleh:
Kelas TI-C8
Kelompok 6

Nama Anggota:

I GEDE ARYA SAPUTRA	434241127
RYAN ERMAULID APRIANSYAH	434241129
ROISATUL UMMAH	434241130

FAKULTAS VOKASI
UNIVERSITAS AIRLANGGA
TAHUN AJARAN 2026/2027

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas terselesaikannya laporan Tugas TM11 Praktikum Machine Learning tentang regresi ini. Laporan ini memuat penerapan dua algoritma ensemble, yaitu AdaBoost Regressor dan Gradient Boosting Regressor, untuk memprediksi harga penutupan ETF USO, beserta evaluasi kedua model dan rancangan antarmuka untuk model terbaik.

Penulis menyadari laporan ini masih memiliki kekurangan. Kritik dan saran yang membangun sangat diharapkan. Semoga laporan ini bermanfaat bagi pembaca.

Surabaya, November 2026

Penulis

DAFTAR ISI

KATA PENGANTAR **2**
DAFTAR ISI **3**
BAB I **5**
PENDAHULUAN **5**
1.1 Latar Belakang 5
1.2 Rumusan Masalah 5
1.3 Tujuan 6
1.4 Batasan Pengerjaan 6
BAB II **7**
DATASET DAN LANDASAN PENGERJAAN **7**
2.1 Dataset 7
2.1.1 Dataset Heart Disease 7
2.1.2 Dataset Mall Customers 7
2.1.3 Ringkasan Dataset 8
2.2 Struktur Variabel Dataset 8
2.2.1 Variabel Numerik 8
2.3.1 Pemeriksaan Struktur dan Ukuran Dataset 9
2.3.2 Pemeriksaan Missing Value 9
2.3.3 Pemeriksaan Nilai Tidak Valid Heart Disease 9
2.3.4 Identifikasi Outlier 9
2.3.5 Pemilihan Fitur 10
2.3.6 Encoding dan Standardisasi 10
2.3.7 Hasil Preprocessing 10
2.4 Konsep Dasar Clustering 11
2.5 Algoritma K-Prototypes 11
2.5.1 Konsep K-Prototypes 11
2.5.2 Perhitungan Jarak Data Numerik dan Kategorikal 11
2.5.3 Penentuan Jumlah Cluster (K) 11
2.5.4 Penentuan Prototipe dan Pembentukan Cluster 12
2.6 Algoritma Fuzzy C-Means (K) 12
2.6.1 Konsep Dasar Fuzzy C-Means 12
2.6.2 Fuzzy Membership 12
2.6.3 Fungsi Objektif 13
2.6.4 Proses Pembentukan Cluster 14
2.7 Algoritma DBSCAN 15
2.7.1 Konsep Dasar DBSCAN 15
2.8 Evaluasi Hasil Clustering 17
2.8.1 Silhouette Score 17
2.8.2 Davies-Bouldin Index (DBI) 17
2.8.3 Chalinski-Harabasz Index (CHI) 18

2.8.4 Perbandingan dan Interpretasi Metrik Evaluasi.....18
BAB III.....19
METODOLOGI DAN IMPLEMENTASI.....19
3.1 Alur Pengerjaan.....19
3.2 Input Dataset.....20
3.3 Implementasi Preprocessing Data.....20
3.4 Implementasi Pemilihan dan Transformasi Fitur.....20
3.5 Implementasi Algoritma K-Means.....21
3.5.1 Penentuan Jumlah Cluster.....22
3.5.2 Proses Clustering.....22
3.5.3 Penentuan Label Clustering.....22
3.5.5 Penyimpanan Hasil Clustering.....22
3.6 Implementasi Evaluasi Hasil K-Means.....22
3.7 Implementasi Visualisasi Hasil Clustering.....23
3.8 Implementasi Algoritma DBSCAN.....23
3.6.1 Penentuan Parameter Epsilon dan MinPts.....23
3.6.2 Perbandingan dan Interpretasi Metrik Evaluasi.....25
3.6.3 Identifikasi Cluster dan Noise.....25
3.6.4 Evaluasi Hasil DBSCAN.....25
3.9 Implementasi Visualisasi Hasil Clustering.....25
3.10 Implementasi Algoritma Fuzzy C-Means.....26
3.10.1 Penentuan Parameter.....26
3.10.2 Proses Clustering.....27
3.10.3 Penentuan Keanggotaan Cluster.....28
3.10.4 Evaluasi Hasil Fuzzy C-Means.....28
3.11 Implementasi Visualisasi Hasil Clustering.....28
3.12 Implementasi Perbandingan Ketiga Algoritma.....29
BAB IV.....30
EVALUASI DAN VISUALISASI.....30
4.1 Hasil Pemeriksaan Dataset.....30
4.8 Hasil Implementasi DBSCAN.....33
4.9 Visualisasi Hasil Clustering.....39
4.9.1 Visualisasi Dataset Heart Diseases.....39
DBSCAN.....39
4.9.2 Visualisasi Dataset Mall Customer.....40
DBSCAN.....40
4.10 Hasil Implementasi Fuzzy C-Means.....40
4.11 Perbandingan Hasil Ketiga Algoritma.....43
4.11.1 Perbandingan K-Means, Fuzzy C-Means, dan DBSCAN pada Heart Disease.....43
4.11.2 Perbandingan K-Means, Fuzzy C-Means, dan DBSCAN pada Mall Customers.....44
4.11.3 Perbandingan Berdasarkan Silhouette Score.....46
4.11.4 Perbandingan Berdasarkan Davies-Bouldin Index.....47
4.11.5 Perbandingan Berdasarkan Calinski-Harabasz Index.....47

4.12 Analisa dan Interpretasi Hasil..... 47
4.12.1 Analisa Karakteristik Cluster.....47
DBSCAN..... 47
4.12.2 Analisa Perbedaan Antar Algoritma.....48
4.12.3 Kelebihan dan Kekurangan Setiap Algoritma..... 48
4.12.4 Algoritma yang Memberikan Hasil Terbaik pada Setiap Dataset.....49
BAB V.....50
PENUTUP.....50
5.1 Kesimpulan.....50
5.2 Saran.....51
DAFTAR PUSTAKA.....53
LAMPIRAN.....54
A. Pembagian Tugas Anggota Kelompok.....54
B. Repository dan Struktur Project..... 55

BAB I
PENDAHULUAN

1.1 Latar Belakang

Harga aset keuangan, termasuk ETF berbasis komoditas, dipengaruhi oleh banyak variabel pasar yang saling berkaitan, seperti harga komoditas lain, indeks saham, nilai tukar, dan indikator makroekonomi. Hubungan antarvariabel tersebut jarang bersifat linear sehingga dibutuhkan model regresi yang mampu menangkap pola kompleks. Pada Modul 11, mahasiswa diminta menerapkan algoritma regresi pada data sekunder dari sumber online. Kelompok genap mengerjakan dua algoritma boosting, yaitu AdaBoost Regressor dan Gradient Boosting Regressor.

Pada laporan ini, kelompok K6 menggunakan dataset FINAL_USO yang berisi data harian pasar keuangan dengan 81 kolom. Variabel target adalah harga penutupan ETF USO (USO_Close). Kedua model dilatih dan diuji pada dataset serta pembagian data yang sama agar perbandingan performanya adil, lalu dievaluasi dengan MAE, MAPE, RMSE, MSE, dan R^2. Model dengan performa terbaik digunakan sebagai dasar pembuatan antarmuka (UI/UX).

Tujuan pengerjaan:

1. Menyiapkan dataset sekunder yang bersih dan bebas kebocoran data (data leakage) untuk kedua model.
2. Melatih dan menguji AdaBoost Regressor dan Gradient Boosting Regressor pada data yang sama.
3. Mengevaluasi kedua model dengan lima metrik regresi dan menentukan model terbaik.
4. Membuat UI/UX untuk model dengan performa terbaik.

1. Mengimplementasikan algoritma K-Means, Fuzzy C-Means, dan DBSCAN pada kedua dataset.
2. Mengetahui jumlah cluster, distribusi anggota, dan noise yang dihasilkan setiap algoritma.
3. Membandingkan kualitas hasil clustering menggunakan metrik evaluasi internal.

BAB II
DATASET DAN LANDASAN PENGERJAAN

2.1 Regresi dan Metrik Evaluasi

Regresi adalah teknik supervised learning yang memodelkan hubungan antara variabel bebas (fitur, X) dan variabel terikat berupa nilai kontinu (target, y). Model

dilatih menggunakan data berlabel sehingga mampu memprediksi nilai target pada data baru. Berbeda dengan klasifikasi yang menghasilkan kelas diskret, keluaran regresi berupa bilangan, dalam kasus ini harga penutupan ETF USO.

Evaluasi dilakukan dengan membandingkan nilai aktual (y_i) dan nilai prediksi ($\hat{y}_i$) pada data testing sebanyak n sampel. Lima metrik yang digunakan:

Metrik	Rumus	Interpretasi
MAE (Mean Absolute Error)	$MAE = (1/n)\ \Sigma\ \|y_i - \hat{y}_i\|$	Rata-rata selisih absolut, satuannya sama dengan target. Semakin kecil semakin baik.
MSE (Mean Squared Error)	$MSE = (1/n)\ \Sigma\ (y_i - \hat{y}_i)^2$	Rata-rata kuadrat galat, memberi penalti besar pada galat besar. Semakin kecil semakin baik.
RMSE (Root Mean Squared Error)	$RMSE = \sqrt{MSE}$	Akar MSE sehingga satuannya sama dengan target. Semakin kecil semakin baik.
MAPE (Mean Absolute Percentage Error)	$MAPE = (100\%/n)\ \Sigma\ \|(y_i - \hat{y}_i)/y_i\|$	Rata-rata galat dalam persen, mudah dibandingkan antardataset. Semakin kecil semakin baik.
R^2 (Koefisien Determinasi)	$R^2 = 1 - \Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2$	Proporsi variansi target yang dijelaskan model. Mendekati 1 berarti baik; bernilai negatif berarti model lebih buruk daripada memprediksi rata-rata.

Pada data deret waktu, evaluasi dilakukan pada data testing yang berada setelah periode training sehingga hasilnya mencerminkan kemampuan model memprediksi data "masa depan".

2.2 AdaBoost dan Gradient Boosting Regressor

Regresi adalah teknik supervised learning yang memodelkan hubungan antara variabel bebas (fitur, X) dan

BAB III
METODOLOGI DAN IMPLEMENTASI

3.1 Dataset dan Preprocessing

a. Sumber dataset.

Dataset yang digunakan adalah FINAL_USO.csv, data sekunder harian pasar keuangan dengan 81 kolom. Sumber online yang sesuai dengan nama dan struktur berkas adalah Kaggle, "Gold price prediction" (https://www.kaggle.com/datasets/suryanachoudhary/gold-price-prediction). Tanggal akses: 8 November 2026. Salinan lokal dataset/FINAL_USO.csv digunakan dalam praktikum dan tersedia di repository kelompok (https://github.com/aryaigede/TM11_K6_ML-Prak).

b. Deskripsi dataset.

Dataset berisi 1.718 baris data harian pada rentang 15 Desember 2011 sampai 31 Desember 2018. Kolom terdiri atas Date serta 80 kolom numerik yang mencakup variabel pasar dan indikator terkait, termasuk kolom berawalan USO_ yang merupakan data ETF USO itu sendiri. Rincian tipe data, jumlah missing value, dan jumlah nilai unik per kolom tersimpan di data_quality_report.csv. Hasil pemeriksaan menunjukkan bahwa seluruh kolom memiliki 0 missing value dan tidak ditemukan data duplikat. **[ISI screenshot hasil pemeriksaan data: info(), missing value]**

c. Fitur (X) dan target (y).

- **Target (y):** USO_Close, harga penutupan ETF USO.
- **Fitur (X):** seluruh kolom numerik selain Date dan selain kolom berawalan USO_. Jumlah fitur: **[ISI jumlah fitur]**.
- **Alasan:** kolom USO_* (misalnya harga open, high, low pada hari yang sama) memuat informasi yang sama dengan target atau sangat berkorelasi langsung dengannya. Jika disertakan, model hanya "menyalin" informasi target sehingga metrik tampak sangat bagus tetapi tidak bermakna (data leakage). Dengan membuangnya, model dipaksa belajar dari variabel pasar lain.

d. Pemeriksaan dan preprocessing.

Langkah yang dilakukan oleh code/01_preprocessing_person1.py:

1. Membaca dataset dan memeriksa struktur, tipe data, missing value, serta jumlah nilai unik (hasil: data_quality_report.csv).
2. Mengubah kolom Date menjadi tipe tanggal dan mengurutkan data berdasarkan tanggal.
3. Menghapus baris duplikat (hasil: dataset_cleaned.csv).
4. Menentukan fitur dan target sesuai bagian c.
5. Menangani missing value dengan imputasi median sebagai perlindungan apabila data sumber berubah. Median dihitung **hanya dari data training**, lalu diterapkan ke data testing agar tidak terjadi data leakage.

Jumlah baris sebelum dan sesudah pembersihan: 1.718 dan 1.718. Jumlah duplikat dihapus: 0. Jumlah missing value: 0.

e. Pembagian data.

Data dibagi secara **kronologis**: 80% awal sebagai data training dan 20% akhir sebagai data testing, tanpa pengacakan. Alasannya, data berbentuk deret waktu sehingga pengacakan akan membuat model "melihat masa depan" saat training. Pembagian yang sama digunakan untuk AdaBoost dan Gradient Boosting. Hasilnya:

	Jumlah baris	**Rentang tanggal**
Training (80%)	1374 Baris	15 Desember 2011 s.d. 10 Agustus 2017
Testing (20%)	344 Baris	11 Agustus 2017 s.d. 31 Desember 2018

Berkas keluaran: train_preprocessed.csv, test_preprocessed.csv, preprocessing_metadata.json, dan visualisasi target_train_test_split.png. **[ISI Gambar 3.1: target_train_test_split.png]**

3.2 Implementasi Kedua Model

Dataset yang digunakan dalam praktikum ini terdiri atas Heart Disease dan Mall Customers. Kedua dataset disimpan dalam format CSV dan dibaca menggunakan library Pandas melalui fungsi read_csv().

Dataset Heart Disease dibaca dari file heart.csv, sedangkan dataset Mall Customers dibaca dari file Mall_Customers.csv. Setelah proses pembacaan, program menampilkan informasi awal berupa nama dataset, jumlah baris dan kolom, lima data pertama, serta struktur data.

Proses pembacaan dataset dilakukan menggunakan dua program preprocessing yang berbeda, yaitu 01_preprocessing_heart.py untuk Heart Disease dan 02_preprocessing_mall.py untuk Mall Customers

```
23      # 1. Membaca dataset
24      df = pd.read_csv(DATA_PATH)
25
26      print("Ukuran dataset:", df.shape)
27      print("\n5 data pertama:")
28      print(df.head())
```

Gambar 3.2. Implementasi input dan pemeriksaan awal dataset.

3.3 Implementasi UI/UX

Preprocessing dilakukan untuk mempersiapkan data sebelum diterapkan algoritma clustering. Tahapan ini bertujuan memastikan data memiliki struktur dan format yang sesuai sehingga dapat digunakan dalam perhitungan jarak oleh algoritma K-Means. Proses preprocessing dilakukan melalui beberapa tahapan yaitu pemeriksaan struktur data, pemeriksaan missing value dan duplikasi, penanganan nilai tidak valid, identifikasi outlier, dan penyimpanan hasil pemeriksaan untuk tahapan berikutnya.

```
print("\nTipe data:")
print(df.dtypes)

print("\nMissing value:")
print(df.isnull().sum())

print("\nJumlah duplikat:", df.duplicated().sum())
```

```
# 2. Menghapus data duplikat
df = df.drop_duplicates().copy()
```

Gambar 3.3-4. Menampilkan Tipe data, missing value dan menghapus data duplikat

3.4 Implementasi Pemilihan dan Transformasi Fitur

Sebelum proses clustering dilakukan, fitur dipilih berdasarkan relevansinya terhadap karakteristik masing-masing dataset. Fitur yang hanya berfungsi sebagai identitas atau label target tidak digunakan sebagai masukan algoritma.

Pada dataset Heart Disease, kolom HeartDisease dikeluarkan karena merupakan label target. Sementara itu, kolom CustomerID pada dataset Mall Customers dikeluarkan karena hanya berfungsi sebagai identitas pelanggan.

Fitur yang digunakan kemudian dikelompokkan menjadi fitur numerik dan kategorikal.

Dataset	Fitur Numerik	Fitur Kategorikal
Heart Disease	Age, RestingBP, Cholesterol, MaxHR, Oldpeak	Sex, ChestPainType, FastingBS, RestingECG, ExerciseAngina, ST_Slope
Mall Customers	Age, Annual Income (k$), Spending Score (1-100)	Gender

Selanjutnya, transformasi fitur dilakukan menggunakan pipeline preprocessing sebagai berikut:

1. SimpleImputer: Mengisi missing value pada fitur numerik menggunakan median dan fitur kategorikal menggunakan modus.
2. StandardScaler: Menstandarkan fitur numerik agar memiliki skala yang sebanding.
3. One-Hot Encoding: Mengubah fitur kategorikal menjadi representasi numerik dalam bentuk kolom indikator.

Hasil transformasi kedua kelompok fitur kemudian digabungkan menjadi satu matriks numerik yang dapat digunakan oleh algoritma K-Means.

```
# 3. Menentukan fitur
numeric_features = [
    "Age", "RestingBP", "Cholesterol", "MaxHR", "Oldpeak"
]

categorical_features = [
    "Sex", "ChestPainType", "FastingBS",
    "RestingECG", "ExerciseAngina", "ST_Slope"
]

target_column = "HeartDisease"
```

Gambar 3.5. Implementasi pemilihan fitur numerik dan kategorikal

3.5 Implementasi Algoritma K-Means

Algoritma K-Means diterapkan untuk mengelompokkan data berdasarkan kemiripan karakteristik antarobservasi. Proses clustering menggunakan matriks fitur yang telah melalui tahap preprocessing. Implementasi dilakukan menggunakan library Scikit-learn dengan parameter KMeans sebagai berikut:

Parameter	Nilai
init	k-means++
n_init	10
max_iter	300
random_state	42
Rentang K	2-6

3.5.1 Penentuan Jumlah Cluster

Penentuan jumlah cluster dilakukan dengan menguji beberapa nilai K, yaitu K = 2, 3, 4, 5, dan 6. Setiap nilai K dijalankan menggunakan algoritma K-Means untuk memperoleh nilai evaluasi yang berbeda.

Evaluasi dilakukan menggunakan Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz Index, dan Inertia. Dalam implementasi ini, Silhouette Score digunakan sebagai dasar utama pemilihan jumlah cluster, yaitu dengan memilih nilai tertinggi dari rentang pengujian.

3.5.2 Proses Clustering

Proses clustering dimulai dengan menentukan centroid awal menggunakan metode k-means++. Selanjutnya, setiap observasi ditempatkan ke cluster dengan centroid terdekat berdasarkan jarak Euclidean.

Setelah seluruh data ditempatkan, centroid diperbarui berdasarkan rata-rata anggota pada masing-masing cluster. Proses tersebut dilakukan secara berulang hingga mencapai kondisi konvergen atau batas iterasi maksimum.

3.5.3 Penentuan Label Clustering

Setelah proses clustering selesai, setiap observasi memperoleh label cluster sesuai hasil pengelompokan. Label tersebut kemudian digabungkan dengan data untuk mengetahui distribusi anggota dan karakteristik masing-masing cluster. Hasil pengelompokan disimpan dalam bentuk CSV agar dapat digunakan dalam analisis dan interpretasi lebih lanjut.

3.5.5 Penyimpanan Hasil Clustering

Hasil implementasi K-Means disimpan dalam folder output masing-masing dataset. File yang dihasilkan meliputi hasil clustering, label cluster, distribusi anggota, profil cluster, dan hasil evaluasi model.

3.6 Implementasi Evaluasi Hasil K-Means

Evaluasi dilakukan untuk mengetahui kualitas hasil pengelompokan yang dihasilkan oleh algoritma K-Means. Beberapa metrik yang digunakan adalah sebagai berikut.

1. Inertia, digunakan untuk mengukur jumlah kuadrat jarak setiap data terhadap centroid cluster masing-masing. Nilai yang lebih kecil menunjukkan data cenderung lebih dekat dengan centroid.
2. Silhouette Score, digunakan untuk mengukur tingkat kekompakan data dalam cluster dan keterpisahannya dari cluster lain. Nilai yang lebih tinggi menunjukkan hasil pengelompokan yang lebih baik.
3. Davies-Bouldin Index (DBI), digunakan untuk mengukur kemiripan antarcluster berdasarkan jarak dan penyebaran anggota. Nilai yang lebih rendah menunjukkan pemisahan cluster yang lebih baik.
4. Calinski-Harabasz Index (CHI), digunakan untuk membandingkan variasi antarcluster dengan variasi dalam cluster. Nilai yang lebih tinggi umumnya menunjukkan struktur cluster yang lebih baik.

Hasil evaluasi dari setiap variasi K disimpan dalam bentuk CSV untuk memudahkan perbandingan dan penentuan jumlah cluster yang digunakan pada model akhir.

3.7 Implementasi Visualisasi Hasil Clustering

Visualisasi dilakukan untuk membantu memahami hasil pengelompokan dan membandingkan performa model pada setiap variasi jumlah cluster. Visualisasi yang dihasilkan meliputi:

1. Elbow Plot, digunakan untuk mengamati perubahan nilai Inertia terhadap jumlah cluster.
2. Silhouette Plot, digunakan untuk membandingkan nilai Silhouette Score pada setiap variasi K.
3. Cluster Distribution Plot, digunakan untuk menampilkan jumlah anggota pada masing-masing cluster.

4. Cluster Profile, digunakan untuk melihat rata-rata karakteristik fitur numerik pada setiap cluster.

Hasil visualisasi disimpan dalam folder output masing-masing dataset dan digunakan sebagai pendukung analisis pada bab hasil dan pembahasan.

3.8 Implementasi Algoritma DBSCAN

DBSCAN diimplementasikan dengan Python menggunakan kelas sklearn.cluster.DBSCAN dari pustaka scikit-learn. Implementasi dibagi menjadi dua skrip, yaitu 07_dbscan_heart.py untuk dataset Heart Disease dan 08_dbscan_mall.py untuk dataset Mall Customers. Masukan kedua skrip adalah hasil preprocessing (matriks fitur yang telah distandardisasi dan di-encode) dari tahap sebelumnya. Hasil akhir disimpan di folder output/heart/dbscan dan output/mall/dbscan.

3.6.1 Penentuan Parameter Epsilon dan MinPts

a. Pemilihan fitur

Pada dataset Heart Disease, DBSCAN menggunakan matriks fitur yang sama dengan K-Means dan Fuzzy C-Means, yaitu 918 baris dan 21 kolom (lima fitur numerik terstandar ditambah kolom hasil one-hot encoding fitur kategorikal), agar hasil ketiga algoritma dapat dibandingkan pada ruang fitur yang sama.

Pada dataset Mall Customers, DBSCAN menggunakan tiga fitur numerik terstandar, yaitu Age, Annual Income (k$), dan Spending Score (1-100), tanpa kolom one-hot Gender. Alasannya, pada jarak Euclidean dua pelanggan yang berbeda gender selalu berbeda pada dua kolom one-hot sehingga jarak minimumnya sebesar akar 2 (sekitar 1,414), terlepas dari kemiripan fitur lainnya. Dengan nilai ε di bawah angka tersebut, pelanggan laki-laki dan perempuan tidak pernah dapat terhubung sehingga cluster yang terbentuk hanya mengikuti pembagian gender, bukan pola perilaku pelanggan. Gender tetap digunakan pada tahap interpretasi untuk melihat komposisi tiap cluster. Matriks yang digunakan berukuran 200 baris dan 3 kolom.

b. Grid pencarian parameter

Karena pemilihan ε dan MinPts secara manual tidak terukur, kedua parameter dicari menggunakan grid search dengan rentang pada tabel berikut. Untuk setiap kombinasi, DBSCAN dijalankan lalu dihitung jumlah cluster, jumlah noise, ukuran cluster, serta Silhouette Score, Davies-Bouldin Index, dan Calinski-Harabasz Index pada data non-noise.

Tabel . Rentang grid pencarian parameter DBSCAN

Dataset	Jumlah fitur	Rentang ε	Nilai MinPts	Jumlah kombinasi
Heart Disease	21	1,0 sampai 5,0 (langkah 0,1)	4, 5, 6, 8, 10, 15, 20, 30	328
Mall Customers	3	0,20 sampai 1,50 (langkah 0,05)	3, 4, 5, 6, 8, 10	162

c. Kriteria pemilihan

Parameter terbaik dipilih dari kombinasi yang memenuhi seluruh kriteria berikut, lalu diambil yang memiliki Silhouette Score tertinggi:

1. menghasilkan minimal dua cluster, karena metrik evaluasi tidak terdefinisi untuk satu cluster dan tujuan clustering adalah mengelompokkan data;
2. persentase noise tidak lebih dari 15% agar sebagian besar data tetap terwakili oleh cluster;
3. setiap cluster memuat minimal 5% dari seluruh data agar tidak terbentuk cluster berukuran sangat kecil yang hanya menandai beberapa titik ekstrem.

Apabila tidak ada kombinasi yang memenuhi seluruh kriteria, digunakan kombinasi cadangan, yaitu kombinasi dengan minimal dua cluster dan noise tidak lebih dari 15% yang memiliki Silhouette Score tertinggi. Hasil dari kombinasi cadangan ditandai sebagai "tidak memenuhi kriteria" sehingga tidak diperlakukan sebagai hasil clustering yang valid pada tahap perbandingan. Sebagai pendukung, k-distance graph dengan k = MinPts terpilih digambar untuk memperlihatkan posisi ε terpilih terhadap sebaran jarak antar-titik.

3.6.2 Perbandingan dan Interpretasi Metrik Evaluasi

Tahapan proses pada kedua skrip adalah sebagai berikut.

1. Membaca matriks fitur hasil preprocessing dan data asli yang telah dibersihkan, lalu memvalidasi bahwa jumlah barisnya sama.
2. Menjalankan grid search dan menghitung metrik tiap kombinasi (disimpan pada file evaluasi/grid).
3. Memilih parameter berdasarkan kriteria pada subbab 3.6.1 dan mencatat statusnya (memenuhi atau tidak memenuhi kriteria).
4. Menjalankan DBSCAN akhir dengan parameter terpilih, lalu menyimpan label cluster (-1 untuk noise) bersama data asli.
5. Menyimpan tabel jumlah anggota, profil cluster, metrik akhir, serta grafik k-distance, distribusi cluster, dan visualisasi hasil.

Inti dari proses clustering ditunjukkan pada potongan kode berikut.

```
from sklearn.cluster import DBSCAN

# X: matriks fitur terstandar (Mall: 3 fitur numerik; Heart: 21 fitur)
labels = DBSCAN(eps=eps, min_samples=ms).fit_predict(X)

result = original.copy()
result["Cluster_DBSCAN"] = labels              # -1 = noise
result["Is_Noise"] = labels == -1
result.to_csv("..._dbscan_clustered.csv", index=False)
```

3.6.3 Identifikasi Cluster dan Noise

Keluaran DBSCAN berupa label untuk setiap data. Label 0, 1, 2, ... menunjukkan nomor cluster, sedangkan label -1 menunjukkan noise. Identifikasi dilakukan dengan menghitung jumlah dan persentase anggota tiap label serta jumlah noise terhadap seluruh data. Karakteristik tiap cluster ditentukan dari rata-rata fitur numerik pada data non-noise. Untuk Mall Customers ditambahkan tabel komposisi gender per cluster, sedangkan untuk Heart Disease ditambahkan proporsi pasien penyakit jantung (kolom HeartDisease, yang tidak digunakan dalam clustering) per cluster sebagai bahan interpretasi.

3.6.4 Evaluasi Hasil DBSCAN

Evaluasi menggunakan Silhouette Score, Davies-Bouldin Index (DBI), dan Calinski-Harabasz Index (CHI). Ketiga metrik membutuhkan label cluster yang lengkap dan minimal dua cluster. Karena noise bukan merupakan cluster, titik berlabel -1 dikeluarkan dari perhitungan sehingga metrik DBSCAN dihitung hanya pada data non-noise. Konsekuensinya, jumlah data yang dievaluasi pada DBSCAN lebih sedikit daripada K-Means dan Fuzzy C-Means yang mengevaluasi seluruh data. Untuk menjaga keadilan, tahap perbandingan (subbab 3.8) menambahkan evaluasi pada subset data non-noise yang sama.

3.9 Implementasi Visualisasi Hasil Clustering

Visualisasi DBSCAN

Visualisasi hasil DBSCAN dibuat dengan matplotlib. Untuk Mall Customers digunakan scatter plot Annual Income terhadap Spending Score dan Age terhadap Spending Score, dengan noise ditandai silang hitam. Untuk Heart Disease yang berdimensi 21, data diproyeksikan ke dua komponen utama dengan PCA; PCA hanya digunakan untuk visualisasi dan tidak menjadi masukan clustering. Pada kedua dataset ditambahkan k-distance graph dan diagram batang distribusi anggota cluster dan noise. Pada Heart Disease ditambahkan grafik jumlah cluster dan persentase noise terhadap ε untuk memperlihatkan sensitivitas DBSCAN terhadap parameter ε.

3.10 Implementasi Algoritma Fuzzy C-Means

Pada tahap ini dilakukan implementasi algoritma Fuzzy C-Means (FCM) untuk mengelompokkan data pada dataset Mall Customers dan Heart Disease. Algoritma FCM digunakan untuk membentuk sejumlah cluster berdasarkan kemiripan karakteristik data dengan mempertimbangkan derajat keanggotaan setiap data terhadap masing-masing cluster. Sebelum proses clustering dilakukan, data yang digunakan merupakan data hasil preprocessing agar memiliki format dan skala yang sesuai untuk proses perhitungan.

Implementasi Fuzzy C-Means dilakukan melalui beberapa tahapan, yaitu penentuan parameter, proses clustering, penentuan keanggotaan cluster, serta evaluasi hasil clustering. Setiap tahapan diterapkan pada kedua dataset untuk memperoleh hasil pengelompokan yang selanjutnya dianalisis berdasarkan metrik evaluasi clustering.

3.10.1 Penentuan Parameter

Pada tahap ini dilakukan penentuan parameter yang digunakan dalam proses clustering menggunakan algoritma Fuzzy C-Means (FCM). Parameter ditentukan berdasarkan karakteristik dataset dan jumlah cluster yang ingin dibentuk.

Implementasi FCM menggunakan parameter berikut:

Parameter	Mall Customers	Heart Disease
Jumlah cluster (c)	4	2
Fuzziness (m)	2	2
Error / toleransi	0,00001	0,00001
Maksimum iterasi	1.000	1.000
Random seed	42	42

Parameter fuzziness sebesar 2 digunakan untuk mengatur tingkat ketidakpastian keanggotaan data terhadap cluster. Nilai toleransi digunakan sebagai batas perubahan fungsi objektif untuk menghentikan iterasi ketika proses clustering telah mencapai kondisi konvergen. Sementara itu, maksimum iterasi membatasi jumlah pengulangan proses perhitungan.

Jumlah cluster pada dataset Mall Customers ditentukan sebanyak 4 cluster, sedangkan dataset Heart Disease menggunakan 2 cluster.

3.10.2 Proses Clustering

Setelah parameter ditentukan, proses clustering dilakukan menggunakan data yang telah melalui tahap preprocessing. Data tersebut digunakan sebagai masukan algoritma Fuzzy C-Means.

Proses clustering diawali dengan pembentukan matriks keanggotaan awal secara acak. Selanjutnya, algoritma menghitung pusat cluster berdasarkan nilai keanggotaan setiap data. Setelah pusat cluster diperoleh, derajat keanggotaan data dihitung kembali berdasarkan jaraknya terhadap masing-masing pusat cluster.

Proses perhitungan tersebut dilakukan secara berulang hingga perubahan fungsi objektif mencapai batas toleransi yang telah ditentukan atau jumlah iterasi maksimum tercapai.

Pada dataset Mall Customers, proses clustering dilakukan untuk membentuk 4 kelompok berdasarkan karakteristik pelanggan. Sementara itu, pada dataset Heart Disease, proses clustering dilakukan untuk membentuk 2 kelompok berdasarkan fitur

hasil preprocessing. Kolom target HeartDisease tidak digunakan sebagai masukan clustering.

```python
def run():
    print("=== FUZZY C-MEANS HEART DISEASE ===")

    X = pd.read_csv(DATA_PATH)
    df = pd.read_csv(CLEANED_PATH)

    if len(X) != len(df):
        raise ValueError("Jumlah baris data preprocessing dan data asli berbed

    best_k = load_best_k()
    print("Jumlah data:", X.shape[0])
    print("Jumlah fitur:", X.shape[1])
    print("Jumlah cluster baseline K-Means:", best_k)

    data = X.to_numpy(dtype=float)
    cntr, u, u0, d, jm, p, fpc = fuzz.cluster.cmeans(
        data.T,
        c=best_k,
        m=2,
        error=1e-5,
        maxiter=1000,
        seed=RANDOM_STATE,
    )
```

```python
def run():
    print("=== FUZZY C-MEANS MALL CUSTOMERS ===")

    X = pd.read_csv(DATA_PATH)
    df = pd.read_csv(CLEANED_PATH)

    if len(X) != len(df):
        raise ValueError("Jumlah baris data preprocessing dan data asli berbed

    best_k = load_best_k()
    print("Jumlah data:", X.shape[0])
    print("Jumlah fitur:", X.shape[1])
    print("Jumlah cluster baseline K-Means:", best_k)

    data = X.to_numpy(dtype=float)
    cntr, u, u0, d, jm, p, fpc = fuzz.cluster.cmeans(
        data.T,
        c=best_k,
        m=2,
        error=1e-5,
        maxiter=1000,
        seed=RANDOM_STATE,
    )
```

Gambar 3.6. Proses clustering menggunakan algoritma Fuzzy C-Means

3.10.3 Penentuan Keanggotaan Cluster

Berbeda dengan K-Means, Fuzzy C-Means menghasilkan derajat keanggotaan yang menunjukkan tingkat keterkaitan setiap data terhadap seluruh cluster. Oleh karena itu, satu data dapat memiliki nilai keanggotaan pada lebih dari satu cluster.

Untuk memperoleh hasil pengelompokan akhir, setiap data ditempatkan ke dalam cluster dengan nilai derajat keanggotaan tertinggi. Dengan demikian, meskipun FCM menggunakan konsep keanggotaan fuzzy, hasil akhirnya dapat disajikan dalam bentuk kelompok yang tegas (hard assignment) untuk keperluan analisis dan evaluasi.

Pada tahap ini, dilakukan penghitungan jumlah anggota pada setiap cluster untuk mengetahui distribusi hasil pengelompokan pada masing-masing dataset.

```python
labels = np.argmax(u, axis=0).astype(int)
```

Gambar 3.7. Penentuan cluster berdasarkan derajat keanggotaan tertinggi

3.10.4 Evaluasi Hasil Fuzzy C-Means

Evaluasi dilakukan untuk mengetahui kualitas hasil clustering Fuzzy C-Means. Pengukuran dilakukan menggunakan tiga metrik, yaitu Silhouette Score, Davies-Bouldin Index, dan Calinski-Harabasz Index.

Hasil evaluasi Fuzzy C-Means pada kedua dataset ditunjukkan pada tabel berikut.

Dataset	Jumlah	Silhouette	Davies-Bouldin	Calinski-Harab

	Cluster	Score	Index	asz Index
Mall Customers	4	0,31912	1,16555	84,65246
Heart Disease	2	0,17551	2,01203	210,52002

Berdasarkan hasil evaluasi pada dataset Mall Customers, diperoleh Silhouette Score sebesar 0,31912. Nilai tersebut menunjukkan bahwa pemisahan antarcluster masih belum terlalu kuat. Davies-Bouldin Index sebesar 1,16555 menunjukkan tingkat kemiripan antarcluster, sedangkan Calinski-Harabasz Index sebesar 84,65246 menggambarkan kualitas pemisahan cluster berdasarkan variasi antarcluster dan dalam cluster.

Pada dataset Heart Disease, diperoleh Silhouette Score sebesar 0,17551, yang menunjukkan bahwa pemisahan antarcluster relatif lemah. Nilai Davies-Bouldin Index sebesar 2,01203 dan Calinski-Harabasz Index sebesar 210,52002 melengkapi pengukuran kualitas pengelompokan pada dataset tersebut.

3.11 Implementasi Visualisasi Hasil Clustering

Visualisasi Fuzzy C means

Visualisasi hasil Fuzzy C-Means dibuat menggunakan matplotlib. Pada dataset Mall Customers, visualisasi ditampilkan dalam bentuk scatter plot untuk memperlihatkan persebaran data ke dalam 4 cluster. Sementara itu, pada dataset Heart Disease yang berdimensi 21, data diproyeksikan menjadi dua komponen utama menggunakan PCA. PCA hanya digunakan untuk visualisasi dan tidak menjadi masukan clustering. Setiap cluster dibedakan berdasarkan warna sesuai hasil penentuan keanggotaan tertinggi (maximum membership). Pada kedua dataset juga ditambahkan diagram batang untuk memperlihatkan distribusi jumlah anggota pada setiap cluster.

3.12 Implementasi Perbandingan Ketiga Algoritma

Perbandingan dilakukan oleh skrip 09_compare_clustering.py yang membaca label cluster hasil K-Means, Fuzzy C-Means, dan DBSCAN, serta matriks fitur hasil preprocessing. Skrip tidak melatih ulang ketiga algoritma. Rancangan perbandingannya adalah sebagai berikut.

1. **Evaluasi utama (cakupan masing-masing).** Metrik K-Means dan Fuzzy C-Means dihitung pada seluruh data, sedangkan metrik DBSCAN dihitung pada data non-noise. Metrik K-Means dan Fuzzy C-Means pada tahap ini divalidasi terhadap nilai yang tersimpan dari eksperimen masing-masing untuk memastikan konsistensi.
2. **Evaluasi pada subset yang sama.** Seluruh algoritma dievaluasi pada baris non-noise DBSCAN yang sama, sehingga jumlah observasi yang dinilai identik.
3. **Dua ruang fitur pada Mall Customers.** Metrik internal bergantung pada ruang fitur tempat jarak dihitung. Karena K-Means dan Fuzzy C-Means

dijalankan pada fitur numerik ditambah one-hot Gender sedangkan DBSCAN pada fitur numerik saja, Mall Customers dievaluasi pada kedua ruang fitur tersebut.

4. **Penilaian validitas.** Setiap hasil clustering dinilai dengan tiga syarat: minimal dua cluster, noise paling banyak 15%, dan setiap cluster minimal 5% data. Hasil yang tidak valid tetap ditampilkan tetapi tidak dihitung sebagai pemenang metrik, karena nilai matriksnya dapat menyesatkan.
5. **Penentuan pemenang.** Untuk setiap metrik ditentukan algoritma terbaik di antara algoritma yang valid: Silhouette dan Calinski-Harabasz semakin tinggi semakin baik, Davies-Bouldin semakin rendah semakin baik.
6. **Kemiripan label.** Kemiripan pengelompokan antar-algoritma diukur dengan Adjusted Rand Index (ARI); label noise (-1) diperlakukan sebagai satu kelompok.

Perlu ditegaskan bahwa clustering tidak memiliki label kebenaran sehingga tidak dikenal "akurasi" seperti pada klasifikasi. Kualitas pada praktikum ini dinilai dengan metrik internal (Silhouette, DBI, dan CHI), dan istilah "lebih baik" dalam laporan ini merujuk pada metrik tersebut.

BAB IV
EVALUASI DAN VISUALISASI

4.1 Hasil Pemeriksaan Dataset

Pemeriksaan awal dilakukan terhadap dataset Heart Disease dan Mall Customers untuk mengetahui struktur, ukuran, tipe data, missing value, serta data duplikat. Hasil pemeriksaan menunjukkan bahwa dataset Heart Disease memiliki 918 baris dan 12 kolom, sedangkan dataset Mall Customers memiliki 200 baris dan 5 kolom.

Pada kedua dataset tidak ditemukan missing value maupun data duplikat. Namun, pada dataset Heart Disease ditemukan nilai 0 pada kolom RestingBP dan Cholesterol yang diperlakukan sebagai nilai tidak valid. Sementara itu, dataset Mall Customers tidak menunjukkan nilai tidak valid yang memerlukan penggantian pada tahap pemeriksaan awal.

Keterangan	Heart Disease	Mall Customers
Jumlah baris awal	918	200
Jumlah kolom awal	12	5
Missing value	0	0
Data duplikat	0	0
Nilai tidak valid yang ditangani	RestingBP: 1; Cholesterol: 172	Tidak ada

Tabel 4.1. Hasil pemeriksaan dataset

4.2 Hasil Preprocessing Data

4.2.1 Dataset art Disease

Pada dataset Heart Disease, ditemukan 1 nilai nol pada kolom RestingBP dan 172 nilai nol pada kolom Cholesterol. Nilai tersebut diganti menggunakan median dari nilai positif pada masing-masing kolom, yaitu 130,0 untuk RestingBP dan 237,0 untuk Cholesterol. Setelah penanganan tersebut, jumlah data tetap sebanyak 918 baris.

Identifikasi outlier dilakukan pada fitur numerik menggunakan metode Interquartile Range (IQR). Hasilnya menunjukkan adanya outlier pada RestingBP sebanyak 27 data, Cholesterol sebanyak 41 data, MaxHR sebanyak 2 data, dan Oldpeak sebanyak 16 data. Outlier pada Age tidak ditemukan. Seluruh outlier dipertahankan agar variasi data tetap terwakili.

Fitur	Jumlah outlier
Age	0
RestingBP	27
Cholesterol	41
MaxHR	2
Oldpeak	16

Tabel 4.2. Hasil Preprocessing dataset Heart

4.2.2 Dataset Mall Customers

Dataset Mall Customers memiliki 200 baris dan 5 kolom. Tidak ditemukan missing value maupun data duplikat. Identifikasi outlier menggunakan metode IQR menunjukkan 2 outlier pada fitur Annual Income (k$), sedangkan fitur Age dan Spending Score (1-100) tidak memiliki outlier. Kedua data outlier tersebut tetap dipertahankan karena masih merupakan variasi karakteristik pelanggan.

Fitur	Jumlah outlier
Age	0
Annual Income (k$)	2
Spending Score (1-100)	0

Tabel 4.3. Hasil Preprocessing dataset Mall

4.3 Hasil Pemilihan dan Transformasi Fitur

Pemilihan fitur dilakukan dengan mengeluarkan kolom yang tidak digunakan sebagai dasar pengelompokan. Pada dataset Heart Disease, kolom HeartDisease tidak disertakan karena merupakan label target. Pada dataset Mall Customers, kolom CustomerID dikeluarkan karena hanya berfungsi sebagai identitas pelanggan.

Dataset	Fitur numerik	Fitur kategorikal	Dimensi matriks akhir
Heart Disease	5	6	918 × 21
Mall Customers	3	1	200 × 5

Tabel 4.3. Hasil pemilihan dan transformasi fitur

Fitur numerik ditransformasikan menggunakan StandardScaler, sedangkan fitur kategorikal diubah menggunakan One-Hot Encoding. Setelah kedua hasil transformasi digabungkan, diperoleh matriks fitur berukuran 918 × 21 untuk Heart Disease dan 200 × 5 untuk Mall Customers. Matriks tersebut menjadi masukan bagi algoritma K-Means.

Hasil preprocessing disimpan dalam berkas heart_features_scaled_encoded.csv dan mall_features_scaled_encoded.csv. Matriks yang sama juga dapat digunakan sebagai masukan algoritma clustering lain agar perbandingan dilakukan pada data dan urutan observasi yang konsisten.

4.4 Hasil Penentuan Jumlah Cluster

Pengujian jumlah cluster dilakukan secara terpisah pada masing-masing dataset dengan rentang K = 2 sampai K = 6. Setiap nilai K dievaluasi menggunakan Inertia, Silhouette Score, Davies-Bouldin Index, dan Calinski-Harabasz Index. Jumlah cluster akhir dipilih berdasarkan nilai Silhouette Score tertinggi dari rentang pengujian.

4.4.1 Dataset Heart Disease

K	Inertia	Silhouette	DBI	CHI
2	**5903,5581**	**0,1752**	**2,0093**	**210,7287**

K	Inertia	Silhouette	DBI	CHI
3	**5474,6811**	**0,1261**	**2,3707**	**149,3341**
4	**5143,7581**	**0,1221**	**2,1853**	**125,4459**
5	**4892,9108**	**0,1047**	**2,2043**	**110,5015**
6	**4659,0620**	**0,1034**	**2,1452**	**101,8916**

Berdasarkan hasil pengujian, nilai Silhouette Score tertinggi diperoleh pada K = 2 sebesar 0,1752. Oleh karena itu, jumlah cluster yang digunakan pada model akhir Heart Disease adalah 2 cluster.

4.4.1 Dataset Heart Disease

K	Inertia	Silhouette	DBI	CHI
2	**487,6586**	**0,2821**	**1,4502**	**85,6305**
3	**393,5986**	**0,2879**	**1,2716**	**76,3181**
4	**303,2875**	**0,3195**	**1,1793**	**85,1485**
5	**264,9906**	**0,3074**	**1,1873**	**79,7633**
6	**230,0140**	**0,3179**	**1,1484**	**79,0369**

Pada dataset Mall Customers, nilai Silhouette Score tertinggi diperoleh pada K = 4 sebesar 0,3195. Dengan demikian, jumlah cluster yang digunakan pada model akhir Mall Customers adalah 4 cluster.

4.5 Hasil Implementasi K-Means

4.5.1 Hasil Clustering Heart Disease

Model K-Means pada dataset Heart Disease menghasilkan 2 cluster dari total 918 data. Cluster 0 terdiri atas 469 data atau 51,09%, sedangkan Cluster 1 terdiri atas 449 data atau 48,91%. Distribusi tersebut menunjukkan bahwa jumlah anggota kedua cluster relatif seimbang.

Cluster	Jumlah anggota	Persentase
0	469	51,09%
1	449	48,91%
Total	918	100,00%

4.5.2 Hasil Clustering Mall Customer

Pada dataset Mall Customers, model K-Means menghasilkan 4 cluster dari total 200 data. Cluster 0 memiliki 65 anggota (32,50%), Cluster 1 memiliki 57 anggota (28,50%), Cluster 2 memiliki 38 anggota (19,00%), dan Cluster 3 memiliki 40 anggota (20,00%).

Cluster	Jumlah anggota	Persentase
0	65	32,50%

1	57	28,50%
2	38	19,00%
3	40	20,00%
Total	200	100,00%

4.6 Evaluasi Hasil K-Means

Evaluasi model akhir dilakukan menggunakan empat metrik internal clustering. Silhouette Score digunakan untuk melihat kekompakan dan pemisahan cluster, Davies-Bouldin Index untuk menilai kemiripan antarcluster, Calinski-Harabasz Index untuk membandingkan variasi antarcluster dan dalam cluster, serta Inertia untuk mengukur jumlah kuadrat jarak data terhadap centroid.

Berdasarkan hasil tersebut, dataset Mall Customers memperoleh Silhouette Score lebih tinggi dan Davies-Bouldin Index lebih rendah dibandingkan Heart Disease. Hal ini menunjukkan bahwa hasil pengelompokan pada Mall Customers memiliki kekompakan dan pemisahan cluster yang relatif lebih baik pada konfigurasi yang diuji. Sementara itu, nilai Silhouette Score Heart Disease sebesar 0,1752 menunjukkan bahwa pemisahan antarcluster masih relatif lemah. Oleh karena itu, hasil clustering perlu diinterpretasikan secara hati-hati.

Nilai Inertia kedua dataset tidak dapat dibandingkan secara langsung karena jumlah observasi, jumlah fitur, dan karakteristik datanya berbeda. Metrik evaluasi tersebut digunakan untuk menilai hasil pada masing-masing dataset, bukan sebagai ukuran akurasi klasifikasi.

4.7 Visualisasi dan Interpretasi Hasil Clustering

Visualisasi hasil clustering digunakan untuk membantu mengamati distribusi dan karakteristik kelompok yang terbentuk. Program menghasilkan visualisasi Elbow Plot, Silhouette Plot, distribusi anggota cluster, serta profil cluster. Visualisasi tersebut dapat digunakan untuk mendukung interpretasi hasil pengelompokan.

Interpretasi karakteristik setiap cluster perlu didasarkan pada nilai rata-rata fitur asli pada berkas profil cluster. Karena berkas profil tersebut belum disertakan pada dokumentasi yang tersedia, uraian mengenai karakteristik spesifik masing-masing cluster belum dicantumkan pada bagian ini. Hasil profil cluster dan grafik terkait perlu dimasukkan setelah nilai aktualnya diperiksa.

4.8 Hasil Implementasi DBSCAN

4.8.1 Hasil Penentuan Parameter

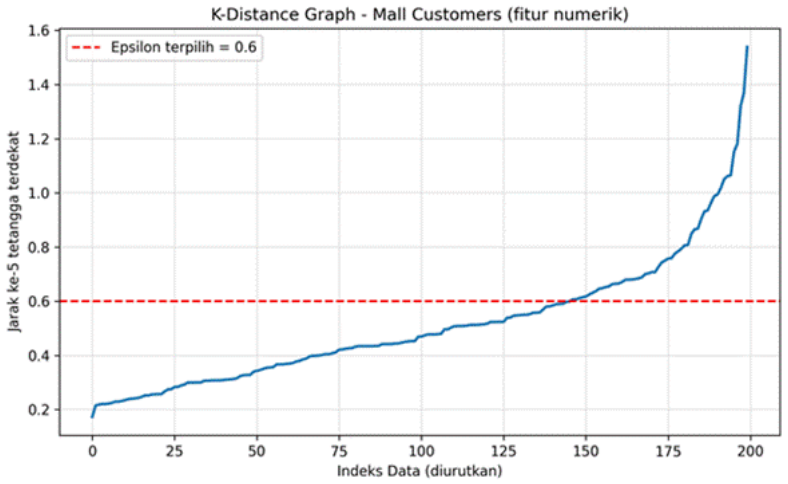
Mall Customers

Dari 162 kombinasi parameter, 54 kombinasi menghasilkan minimal dua cluster, tetapi hanya dua kombinasi yang memenuhi seluruh kriteria (noise paling banyak 15% dan setiap cluster minimal 5% data). Kedua kombinasi tersebut ditampilkan pada tabel berikut.

Tabel . Kombinasi parameter DBSCAN Mall Customers yang memenuhi kriteria

ε	MinPts	Jumlah cluster	Ukuran cluster	Noise	Silhouette	DBI	CHI
0,60 (terpilih)	5	2	137, 35	28 (14,00%)	0,2730	1,0204	54,4214
0,65	5	2	143, 36	21 (10,50%)	0,265	1,033	54,920

Kombinasi ε = 0,60 dan MinPts = 5 dipilih karena memiliki Silhouette Score tertinggi. Pada k-distance graph berikut, garis ε terpilih berada pada daerah kurva yang mulai menanjak, yaitu peralihan dari titik di daerah padat ke titik di daerah jarang.



Gambar . K-distance graph DBSCAN pada dataset Mall Customers

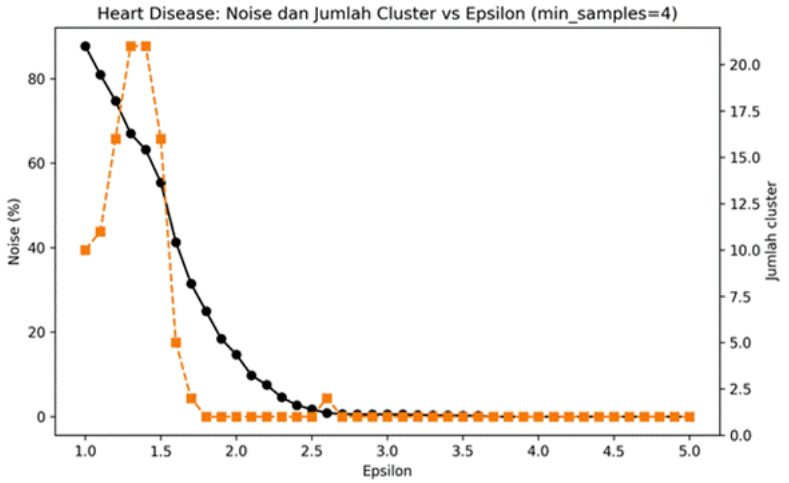
Heart Disease

Dari 328 kombinasi parameter, 48 kombinasi menghasilkan minimal dua cluster, tetapi hanya satu kombinasi yang sekaligus memiliki noise tidak lebih dari 15%, dan kombinasi tersebut tidak memenuhi syarat ukuran cluster. Tidak ada satu pun kombinasi yang memenuhi seluruh kriteria. Perilaku DBSCAN terhadap ε pada MinPts = 5 ditunjukkan pada tabel berikut.

Tabel . Pengaruh ε terhadap hasil DBSCAN Heart Disease (MinPts = 5)

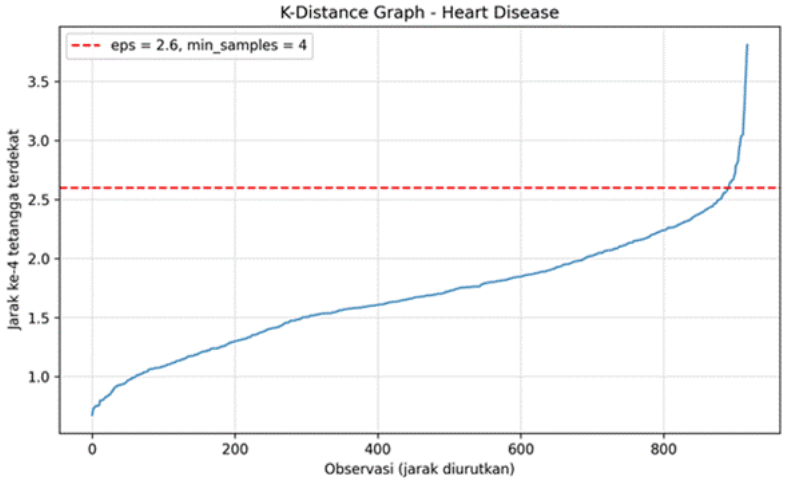
ε	Jumlah cluster	Ukuran cluster terkecil	Ukuran cluster terbesar	Noise	Noise (%)
1,0	5	6	31	844	91,94
1,5	6	4	181	569	61,98
2,0	2	1	778	139	15,14
2,5	1	900	900	18	1,96
3,0	1	913	913	5	0,54
4,0	1	918	918	0	0,00

Tabel tersebut memperlihatkan bahwa pada ε kecil hampir seluruh data menjadi noise dan cluster yang terbentuk sangat kecil, sedangkan pada ε besar seluruh data menyatu menjadi satu cluster. Tidak ada rentang ε yang menghasilkan beberapa cluster yang bermakna dengan noise yang wajar. Hal ini ditunjukkan juga oleh grafik berikut.



Gambar . Persentase noise dan jumlah cluster terhadap ε pada Heart Disease (MinPts = 5)

Karena tidak ada kombinasi yang memenuhi kriteria, digunakan kombinasi cadangan ε = 2,6 dan MinPts = 4 (minimal dua cluster, noise paling banyak 15%, Silhouette tertinggi). Kombinasi ini menghasilkan dua cluster berukuran 906 dan 4 anggota serta 8 noise, sehingga cluster terkecilnya hanya 0,44% dari data dan hasilnya ditandai tidak memenuhi kriteria.



Gambar . K-distance graph DBSCAN pada dataset Heart Disease

4.8.2 Hasil Clustering Heart Disease

DBSCAN pada Heart Disease dengan ε = 2,6 dan MinPts = 4 menghasilkan dua cluster dan delapan noise. Cluster 0 memuat 906 pasien (98,69%) sehingga

hampir seluruh data menyatu dalam satu cluster besar. Cluster 1 hanya memuat 4 pasien (0,44%), dan 8 pasien (0,87%) ditandai sebagai noise.

Tabel . Profil rata-rata fitur numerik cluster DBSCAN pada Heart Disease (data non-noise)

Cluster	Jumlah	Age	RestingBP	Cholesterol	MaxHR	Oldpeak
Cluster 0	906	53,52	132,59	241,03	136,87	0,88
Cluster 1	4	42,25	129,50	501,00	136,75	0,25

Cluster 1 berisi empat pasien dengan kadar kolesterol yang sangat tinggi (rata-rata 501,00) dan nilai fitur lain yang tidak berbeda jauh dari Cluster 0. Dengan demikian cluster ini bukan kelompok pasien yang bermakna secara umum, melainkan sekumpulan titik ekstrem pada satu fitur. Delapan pasien noise juga memiliki nilai ekstrem, yaitu kolesterol dengan rata-rata 360,9 (rentang 113 sampai 603) dan Oldpeak dengan rentang -2,6 sampai 6,2. Sebagai bahan interpretasi, proporsi pasien penyakit jantung pada tiap kelompok disajikan pada tabel berikut; kolom HeartDisease tidak digunakan dalam clustering.

Tabel . Proporsi pasien penyakit jantung pada hasil DBSCAN Heart Disease

Kelompok	Jumlah	Penyakit jantung	Proporsi (%)
Cluster 0	906	498	54,97
Cluster 1	4	4	100,00
Noise	8	6	75,00
Seluruh data	918	508	55,34

Proporsi pada Cluster 0 (54,97%) hampir sama dengan proporsi seluruh data (55,34%), yang menunjukkan Cluster 0 tidak memisahkan pasien berisiko tinggi dan rendah. Proporsi 100% pada Cluster 1 dan 75% pada noise didasarkan pada jumlah pasien yang sangat sedikit (4 dan 8) sehingga tidak dapat digeneralisasi.

4.8.3 Hasil Clustering Mall Customer

DBSCAN pada Mall Customers dengan $\varepsilon = 0{,}60$ dan MinPts = 5 menghasilkan dua cluster dan 28 noise (14,00%).

Tabel . Profil rata-rata fitur cluster DBSCAN pada Mall Customers (data non-noise)

Cluster	Jumlah	Age	Annual Income (k$)	Spending Score
Cluster 0	137	40,97	51,61	45,34
Cluster 1	35	32,74	82,54	82,80

1. **Cluster 0 (137 pelanggan, 68,50%):** kelompok besar pelanggan berusia menengah (sekitar 41 tahun) dengan pendapatan dan skor belanja menengah

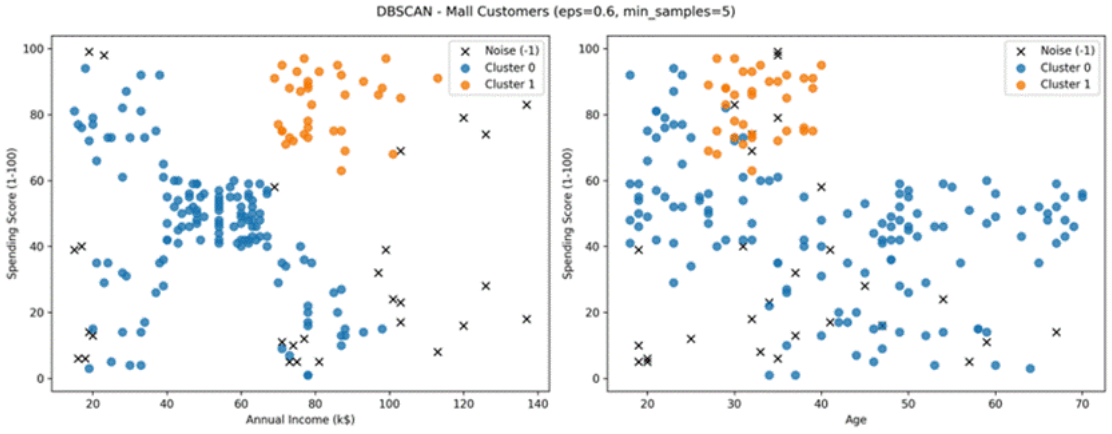
(sekitar 52 k$ dan 45). Kelompok ini mencakup daerah padat di bagian tengah sebaran pelanggan.

2. **Cluster 1 (35 pelanggan, 17,50%):** kelompok pelanggan yang lebih muda (sekitar 33 tahun) dengan pendapatan tinggi (sekitar 83 k$) dan skor belanja tinggi (sekitar 83). Kelompok ini identik dengan segmen pelanggan potensial.
3. **Noise (28 pelanggan, 14,00%):** pelanggan di daerah jarang pada tepi sebaran. Rata-rata pendapatan noise 76,9 k$ dengan simpangan baku 42,2 (rentang 15 sampai 137) dan skor belanja rata-rata 33,2 (rentang 5 sampai 99), sehingga noise mencakup pelanggan dengan pendapatan atau skor belanja ekstrem, misalnya berpendapatan tinggi dengan skor belanja rendah.

Tabel . Komposisi gender per kelompok hasil DBSCAN pada Mall Customers

Kelompok	Female	Male	Female (%)
Cluster 0	77	60	56,2
Cluster 1	19	16	54,3
Noise	16	12	57,1

Komposisi gender pada setiap kelompok relatif seimbang dan mirip dengan komposisi seluruh data, sehingga cluster yang terbentuk memang didasarkan pada Age, Annual Income, dan Spending Score, bukan pada gender. Dibandingkan segmentasi yang dihasilkan K-Means dan Fuzzy C-Means dengan empat cluster, DBSCAN tidak memisahkan segmen-segmen lain secara tersendiri; sebagian pelanggan pada segmen tersebut menyatu ke Cluster 0 dan sebagian lain menjadi noise.



Gambar . Hasil clustering DBSCAN pada Mall Customers (ε = 0,60; MinPts = 5)

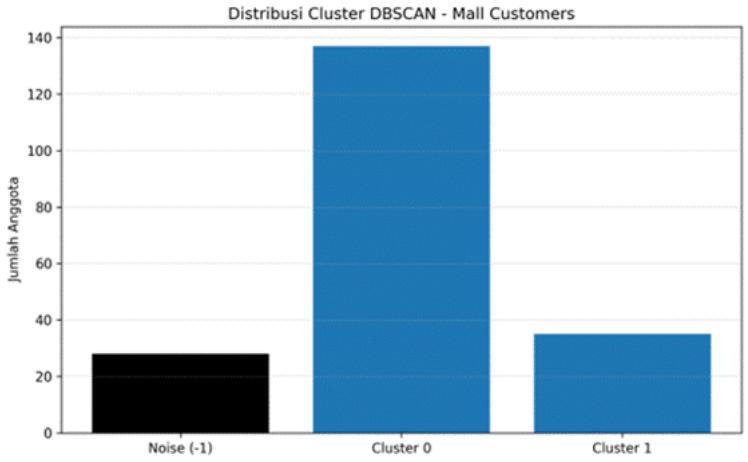
4.8.4 Distribusi Anggota Cluster dan Noise

Tabel . Distribusi anggota cluster DBSCAN

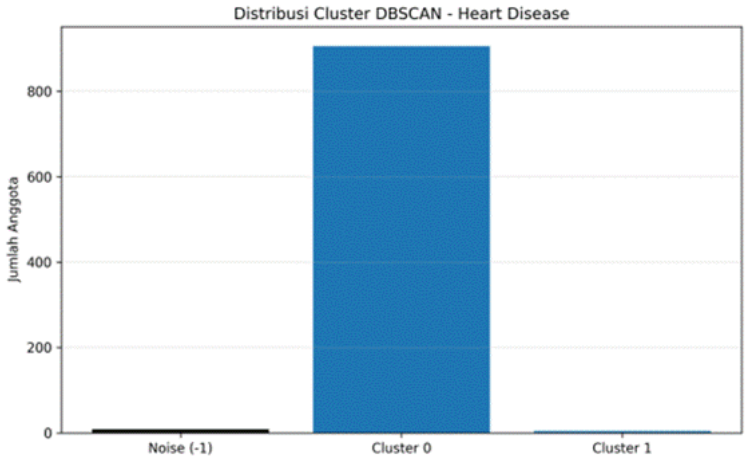
Dataset	Kelompok	Jumlah anggota	Persentase (%)

Mall Customers	Cluster 0	137	68,50
Mall Customers	Cluster 1	35	17,50
Mall Customers	Noise (-1)	28	14,00
Mall Customers	Total	200	100,00
Heart Disease	Cluster 0	906	98,69
Heart Disease	Cluster 1	4	0,44
Heart Disease	Noise (-1)	8	0,87
Heart Disease	Total	918	100,00

Pada Mall Customers, noise sebesar 14,00% hampir mencapai batas kriteria 15%, yang wajar karena ε dipilih cukup ketat agar dua kelompok padat dapat terpisah. Pada Heart Disease, noise hanya 0,87% bukan karena data bersih dari outlier, tetapi karena ε yang diperlukan agar tidak terlalu banyak noise sudah cukup besar untuk menyatukan hampir seluruh data ke dalam satu cluster.



Gambar . Distribusi anggota cluster dan noise DBSCAN pada Mall Customers



Gambar . Distribusi anggota cluster dan noise DBSCAN pada Heart Disease

Secara umum, jumlah noise pada DBSCAN bergantung pada ε dan MinPts. Pada Heart Disease yang berdimensi 21, jarak antar-titik cenderung besar dan data tersebar jarang (curse of dimensionality), sehingga pada ε kecil hampir seluruh data tidak memiliki cukup tetangga dan menjadi noise. K-Means dan Fuzzy C-Means tidak memiliki konsep noise karena setiap data selalu dimasukkan ke centroid terdekat atau keanggotaan tertinggi, sehingga noise bernilai nol bukan berarti data bebas outlier.

4.8.5 Evaluasi DBSCAN

Tabel . Metrik evaluasi DBSCAN (dihitung pada data non-noise)

Dataset	Fitur	ε / MinPts	Data dievaluasi	Silhouette	DBI	CHI	Status kriteria
Mall Customers	3 numerik	0,60 / 5	172	0,2730	1,0204	54,4214	Memenuhi
Heart Disease	21 fitur	2,6 / 4	910	0,3575	0,8277	13,8113	Tidak memenuhi

Pada Mall Customers, Silhouette Score sebesar 0,2730 menunjukkan struktur cluster yang lemah. DBI sebesar 1,0204 dan CHI sebesar 54,4214 pada tabel ini hanya bermakna jika dibandingkan dengan algoritma lain, yang dibahas pada subbab 4.7.

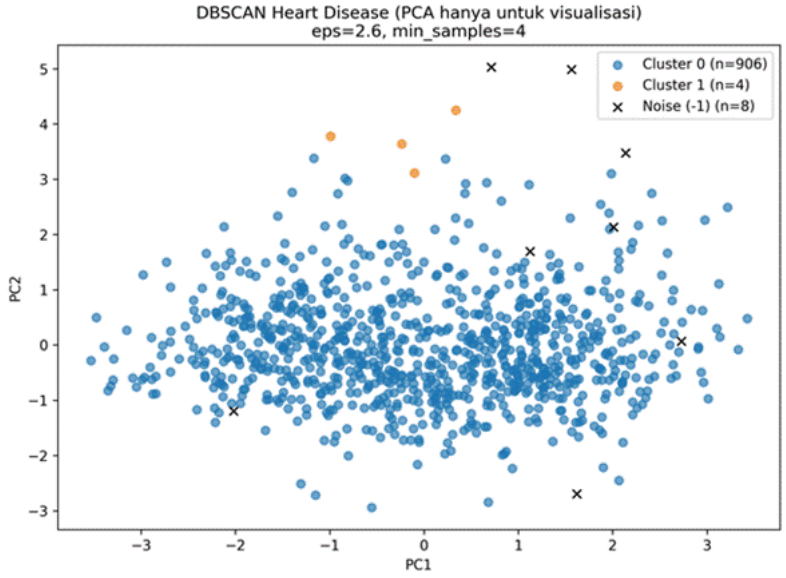
Pada Heart Disease, nilai Silhouette (0,3575) dan DBI (0,8277) tampak baik, tetapi nilai tersebut tidak dapat dipercaya sebagai indikator kualitas clustering. Cluster 1 hanya beranggota empat pasien yang jaraknya jauh dari Cluster 0 sehingga Silhouette dan DBI terdongkrak, sedangkan CHI yang rendah (13,8113) mencerminkan bahwa hampir seluruh data berada dalam satu cluster. Oleh karena itu hasil DBSCAN pada Heart Disease dinyatakan tidak valid sebagai segmentasi.

4.9 Visualisasi Hasil Clustering

4.9.1 Visualisasi Dataset Heart Diseases

DBSCAN

Gambar berikut memperlihatkan proyeksi PCA dua dimensi hasil DBSCAN pada Heart Disease. Hampir seluruh titik berada dalam Cluster 0, sedangkan Cluster 1 dan noise berupa titik yang jumlahnya sangat sedikit dan tersebar di tepi.



Gambar 7. Proyeksi PCA hasil DBSCAN pada Heart Disease (ε = 2,6; MinPts = 4)

4.9.2 Visualisasi Dataset Mall Customer

DBSCAN

Visualisasi hasil DBSCAN pada Mall Customers ditunjukkan pada subbab 4.5.3. Pada scatter plot Annual Income terhadap Spending Score, Cluster 1 menempati daerah pendapatan dan skor belanja tinggi, Cluster 0 menempati daerah tengah, dan noise tersebar di tepi sebaran.

4.10 Hasil Implementasi Fuzzy C-Means

Implementasi algoritma Fuzzy C-Means dilakukan pada dataset Heart Disease dan Mall Customers menggunakan parameter yang telah ditentukan. Hasil clustering diperoleh berdasarkan derajat keanggotaan setiap data terhadap masing-masing cluster. Untuk menyajikan hasil pengelompokan, setiap data ditempatkan pada cluster dengan nilai keanggotaan tertinggi.

4.10.1 Hasil Penentuan Parameter

Pada proses clustering, digunakan parameter Fuzzy C-Means yang berbeda berdasarkan jumlah cluster pada masing-masing dataset. Parameter yang digunakan ditampilkan pada tabel berikut.

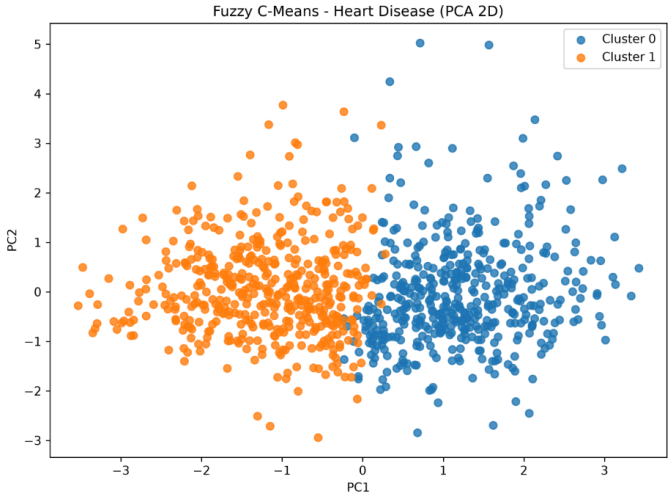
Parameter	Heart Disease	Mall Customers
Jumlah data	918	200
Jumlah cluster	2	4
Fuzziness (m)	2	2
Error / toleransi	0,00001	0,00001
Maksimum iterasi	1.000	1.000
Random seed	42	42

Parameter tersebut digunakan untuk menjalankan proses clustering hingga mencapai kondisi konvergen atau memenuhi batas iterasi maksimum.

4.10.2 Hasil Clustering Heart Disease

Berdasarkan proses clustering menggunakan algoritma Fuzzy C-Means, dataset Heart Disease yang terdiri dari 918 data berhasil dikelompokkan menjadi 2 cluster. Pengelompokan dilakukan berdasarkan kemiripan karakteristik fitur yang telah melalui tahap preprocessing, tanpa menggunakan kolom target HeartDisease.

Hasil clustering menunjukkan bahwa setiap data memperoleh derajat keanggotaan terhadap kedua cluster. Cluster akhir ditentukan berdasarkan nilai keanggotaan tertinggi dari masing-masing data.

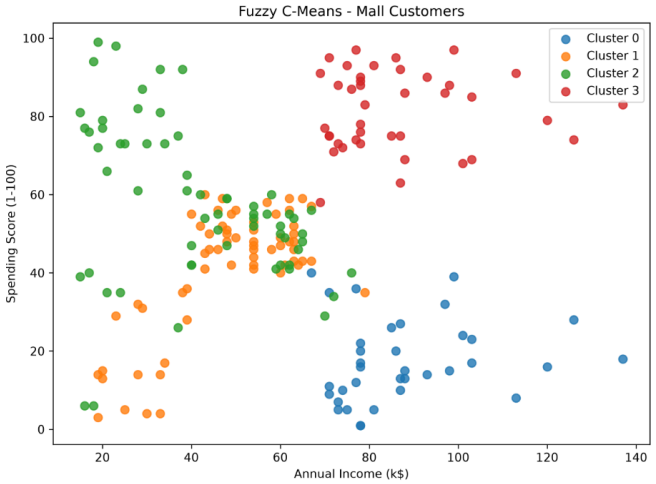


Gambar 8. Hasil Clustering Heart Fuzzy C-Means

4.10.3 Hasil Clustering Mall Customers

Pada dataset Mall Customers, algoritma Fuzzy C-Means berhasil mengelompokkan 200 data pelanggan ke dalam 4 cluster. Proses pengelompokan dilakukan berdasarkan karakteristik fitur pelanggan yang telah melalui tahap preprocessing.

Setiap pelanggan memiliki derajat keanggotaan terhadap keempat cluster. Hasil pengelompokan akhir ditentukan dengan memilih cluster yang memiliki nilai derajat keanggotaan tertinggi.

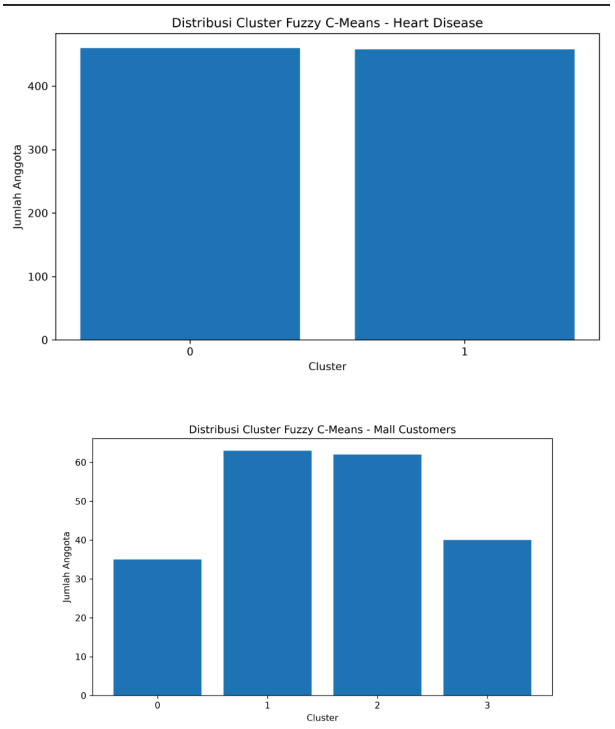


Gambar 9. Hasil Clustering Mall Fuzzy C-Means

4.10.4 Distribusi Keanggotaan dan Karakteristik Cluster

Distribusi keanggotaan digunakan untuk mengetahui jumlah data yang termasuk ke dalam setiap cluster berdasarkan nilai derajat keanggotaan tertinggi. Hasil distribusi tersebut dapat digunakan untuk melihat keseimbangan jumlah anggota pada masing-masing cluster.

Pada dataset Heart Disease, hasil clustering menghasilkan 2 kelompok, sedangkan dataset Mall Customers menghasilkan 4 kelompok. Distribusi jumlah anggota setiap cluster ditampilkan dalam diagram batang.



Gambar 10. Distribusi jumlah anggota cluster hasil Fuzzy C-Means

Selain distribusi anggota, karakteristik setiap cluster dapat dianalisis melalui nilai rata-rata fitur pada masing-masing kelompok. Analisis ini bertujuan untuk mengetahui perbedaan karakteristik antarcluster.

4.10.5 Evaluasi Fuzzy C-Means

Evaluasi dilakukan untuk mengukur kualitas hasil clustering menggunakan tiga metrik, yaitu Silhouette Score, Davies-Bouldin Index, dan Calinski-Harabasz Index. Hasil evaluasi Fuzzy C-Means pada kedua dataset ditampilkan pada tabel berikut.

Dataset	Jumlah Cluster	Silhouette Score	Davies-Bouldin Index	Calinski-Harabasz Index
Heart Disease	2	0,17551	2,01203	210,52002
Mall Customers	4	0,31912	1,16555	84,65246

Pada dataset Heart Disease, diperoleh Silhouette Score sebesar 0,17551, Davies-Bouldin Index sebesar 2,01203, dan Calinski-Harabasz Index sebesar 210,52002. Hasil tersebut menunjukkan bahwa pemisahan antarcluster masih relatif lemah.

Sementara itu, pada dataset Mall Customers diperoleh Silhouette Score sebesar 0,31912, Davies-Bouldin Index sebesar 1,16555, dan Calinski-Harabasz Index sebesar 84,65246. Hasil ini menunjukkan kualitas pemisahan cluster yang lebih baik berdasarkan Silhouette Score dan Davies-Bouldin Index dibandingkan dataset Heart Disease.

4.11 Perbandingan Hasil Ketiga Algoritma

Bagian ini membandingkan K-Means, Fuzzy C-Means, dan DBSCAN menggunakan hasil yang telah dijelaskan pada subbab sebelumnya. K-Means dan Fuzzy C-Means dijalankan dengan K = 4 pada Mall Customers dan K = 2 pada Heart Disease; Fuzzy C-Means menggunakan fuzziness m = 2. Seluruh nilai metrik berasal dari file keluaran skrip perbandingan.

4.11.1 Perbandingan K-Means, Fuzzy C-Means, dan DBSCAN pada Heart Disease

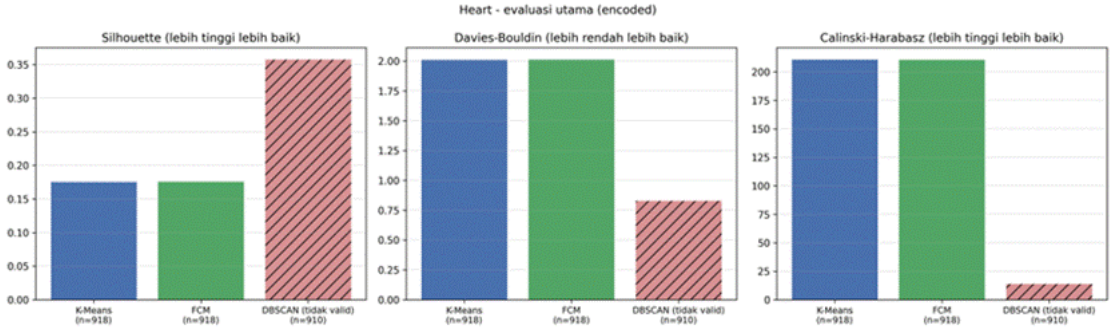
Tabel . Perbandingan algoritma pada Heart Disease (cakupan evaluasi masing-masing)

Algoritma	Jumlah cluster	Ukuran cluster	Noise	Data dievaluasi	Silhouette	DBI	CHI	Valid
K-Means	2	469, 449	0	918	0,1752	2,0093	210,7287	Ya
Fuzzy C-Means	2	460, 458	0	918	0,1755	2,0120	210,5200	Ya
DBSCAN	2	906, 4	8	910	0,3575	0,8277	13,8113	Tidak

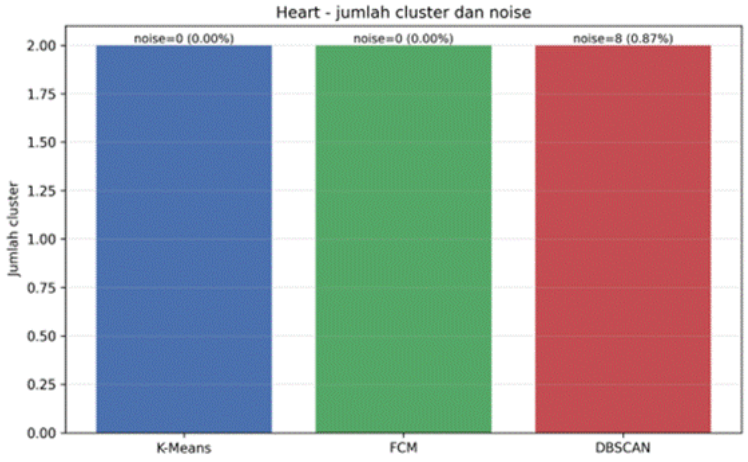
Tabel . Perbandingan pada subset 910 baris non-noise DBSCAN yang sama (Heart Disease)

Algoritma	Jumlah cluster	Silhouette	DBI	CHI	Valid
K-Means	2	0,1769	1,9969	213,6010	Ya
Fuzzy C-Means	2	0,1771	1,9992	213,3480	Ya
DBSCAN	2	0,3575	0,8277	13,8113	Tidak

K-Means dan Fuzzy C-Means menghasilkan dua cluster dengan ukuran yang seimbang dan nilai metrik yang hampir sama. DBSCAN tampak unggul pada Silhouette dan DBI, tetapi hasil tersebut tidak valid (cluster terkecil hanya 4 pasien) sehingga tidak diperhitungkan sebagai pemenang. Pada subset data yang sama, pola yang sama tetap muncul.



Gambar 8. Perbandingan metrik evaluasi ketiga algoritma pada Heart Disease (batang berarsir: hasil tidak valid)



Gambar 9. Jumlah cluster dan noise ketiga algoritma pada Heart Disease

4.11.2 Perbandingan K-Means, Fuzzy C-Means, dan DBSCAN pada Mall Customers

Tabel . Perbandingan algoritma pada Mall Customers - ruang fitur numerik dan one-hot Gender (cakupan evaluasi masing-masing)

Algoritma	Jumlah cluster	Ukuran cluster	Noise	Data dievaluasi	Silhouette	DBI	CHI
K-Means	4	65, 57, 38, 40	0	200	0,3195	1,1793	85,1485
Fuzzy C-Means	4	35, 63, 62, 40	0	200	0,3191	1,1656	84,6525
DBSCAN	2	137, 35	28	172	0,2206	1,2889	43,4596

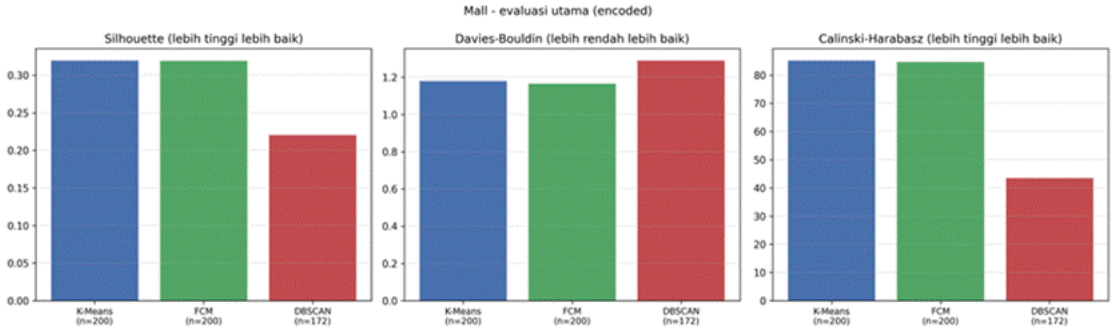
Tabel . Perbandingan algoritma pada Mall Customers - ruang fitur numerik saja (ruang DBSCAN)

Algoritma	Jumlah cluster	Data dievaluasi	Silhouette	DBI	CHI
K-Means	4	200	0,4047	0,9335	125,3909
Fuzzy C-Means	4	200	0,4024	0,9218	123,5323
DBSCAN	2	172	0,2730	1,0204	54,4214

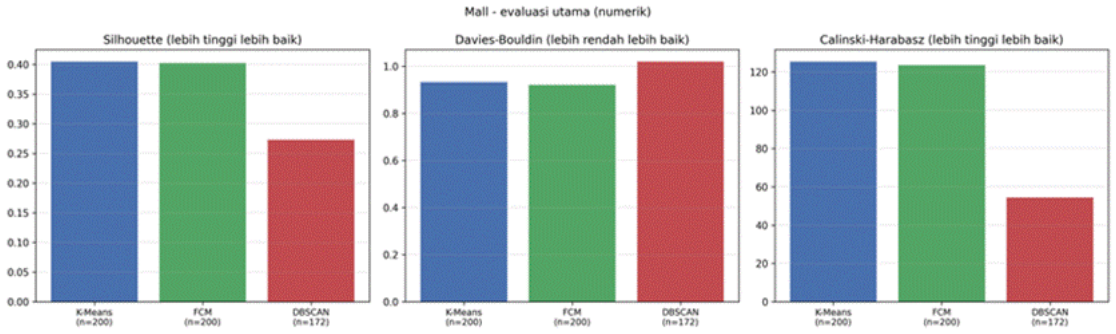
Tabel . Perbandingan pada subset 172 baris non-noise DBSCAN yang sama (Mall Customers)

Algoritma	Silhouette (numerik + Gender)	DBI (numerik + Gender)	CHI (numerik + Gender)	Silhouette (numerik)	DBI (numerik)	CHI (numerik)
K-Means	0,3241	1,2059	77,1546	0,4226	0,8981	123,5807
Fuzzy C-Means	0,3233	1,1779	77,3779	0,4192	0,8752	122,5053
DBSCAN	0,2206	1,2889	43,4596	0,2730	1,0204	54,4214

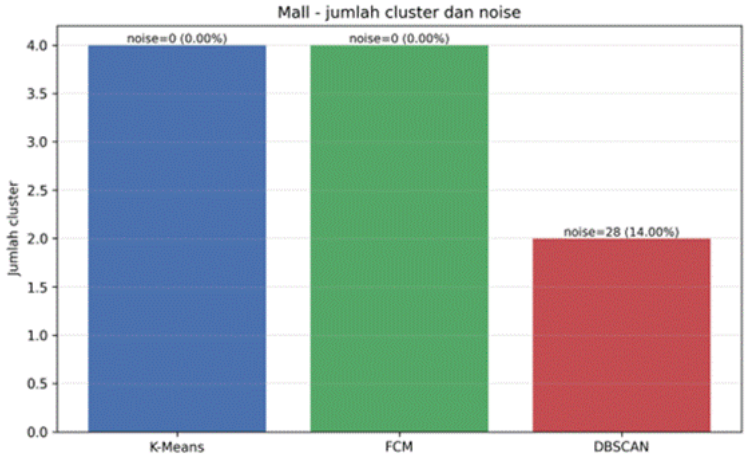
Pada kedua ruang fitur dan pada subset data yang sama, K-Means dan Fuzzy C-Means memiliki nilai metrik yang sangat mirip dan konsisten lebih baik daripada DBSCAN pada ketiga metrik. Konsistensi hasil pada ruang fitur numerik saja menunjukkan bahwa keunggulan K-Means dan Fuzzy C-Means bukan akibat perbedaan ruang fitur.



Gambar 10. Perbandingan metrik evaluasi ketiga algoritma pada Mall Customers (ruang numerik dan one-hot Gender)



Gambar . Perbandingan metrik evaluasi ketiga algoritma pada Mall Customers (ruang numerik saja)



Gambar 12. Jumlah cluster dan noise ketiga algoritma pada Mall Customers

4.11.3 Perbandingan Berdasarkan Silhouette Score

Tabel . Silhouette Score ketiga algoritma (semakin tinggi semakin baik)

Dataset	K-Means	Fuzzy C-Means	DBSCAN	Terbaik (valid)
Mall Customers	0,3195	0,3191	0,2206	K-Means
Heart Disease	0,1752	0,1755	0,3575 (tidak valid)	Fuzzy C-Means

Pada Mall Customers, K-Means memiliki Silhouette tertinggi, tetapi selisihnya dengan Fuzzy C-Means sangat kecil (0,0004). Pada Heart Disease, Fuzzy C-Means unggul tipis (selisih 0,0003) di antara hasil yang valid. Nilai Silhouette sekitar 0,18 pada Heart Disease menunjukkan struktur cluster yang lemah pada K-Means dan Fuzzy C-Means.

4.11.4 Perbandingan Berdasarkan Davies-Bouldin Index

Tabel . Davies-Bouldin Index ketiga algoritma (semakin rendah semakin baik)

Dataset	K-Means	Fuzzy C-Means	DBSCAN	Terbaik (valid)
Mall Customers	1,1793	1,1656	1,2889	Fuzzy C-Means
Heart Disease	2,0093	2,0120	0,8277 (tidak valid)	K-Means

Pada Mall Customers, Fuzzy C-Means sedikit lebih baik daripada K-Means, sedangkan DBSCAN paling tinggi (paling buruk). Pada Heart Disease, K-Means sedikit lebih baik di antara hasil yang valid; nilai DBI DBSCAN yang rendah disebabkan cluster kecil yang terpisah jauh dan tidak diperhitungkan.

4.11.5 Perbandingan Berdasarkan Calinski-Harabasz Index

Tabel . Calinski-Harabasz Index ketiga algoritma (semakin tinggi semakin baik)

Dataset	K-Means	Fuzzy C-Means	DBSCAN	Terbaik (valid)
Mall Customers	85,1485	84,6525	43,4596	K-Means
Heart Disease	210,7287	210,5200	13,8113 (tidak valid)	K-Means

K-Means unggul tipis pada kedua dataset. DBSCAN memiliki nilai CHI yang jauh lebih rendah, yang sejalan dengan struktur cluster DBSCAN yang kurang padat (Mall Customers) atau hampir tunggal (Heart Disease).

Tabel . Rekapitulasi jumlah metrik yang dimenangkan (dari tiga metrik, hanya algoritma valid)

Dataset	K-Means	Fuzzy C-Means	DBSCAN
Mall Customers	2	1	0
Heart Disease	2	1	0 (hasil tidak valid)

4.12 Analisa dan Interpretasi Hasil

4.12.1 Analisa Karakteristik Cluster

DBSCAN

Pada Mall Customers, DBSCAN menghasilkan dua kelompok padat, yaitu pelanggan berpendapatan dan belanja menengah (Cluster 0) dan pelanggan muda berpendapatan dan belanja tinggi (Cluster 1), serta 14% pelanggan sebagai noise. Pada Heart Disease, DBSCAN tidak menghasilkan segmentasi yang bermakna:

hampir seluruh pasien berada dalam satu cluster, sedangkan cluster kedua dan noise hanya berisi pasien dengan nilai ekstrem (terutama kolesterol). Rincian karakteristik terdapat pada subbab 4.5.2 dan 4.5.3.

4.12.2 Analisa Perbedaan Antar Algoritma

Tabel 20. Kemiripan label antar-algoritma (Adjusted Rand Index)

Pasangan algoritma	Mall Customers	Heart Disease
K-Means dan Fuzzy C-Means	0,932	0,953
K-Means dan DBSCAN	0,302	0,000
Fuzzy C-Means dan DBSCAN	0,314	0,000

K-Means dan Fuzzy C-Means menghasilkan pengelompokan yang hampir identik (ARI 0,93 sampai 0,95). Hal ini wajar karena keduanya berbasis centroid dan jarak Euclidean; perbedaannya hanya pada keanggotaan, yaitu Fuzzy C-Means memberikan derajat keanggotaan, sedangkan K-Means keanggotaan tegas. Setelah derajat keanggotaan diubah menjadi label dengan keanggotaan tertinggi, hasil keduanya hampir sama.

DBSCAN berbeda secara mendasar karena membentuk cluster berdasarkan kepadatan. Pada Mall Customers, ARI sekitar 0,30 menunjukkan kemiripan yang rendah karena DBSCAN hanya membentuk dua cluster dengan sebagian data sebagai noise, sedangkan K-Means dan Fuzzy C-Means membagi data menjadi empat segmen. Pada Heart Disease, ARI mendekati nol karena DBSCAN hampir tidak membagi data sehingga tidak ada kesesuaian pengelompokan dengan dua cluster seimbang milik K-Means dan Fuzzy C-Means.

Penyebab utama DBSCAN kurang sesuai pada kedua dataset adalah struktur datanya. Pada Mall Customers, sebaran Age yang luas membuat segmen-segmen saling berdekatan di ruang tiga fitur sehingga tidak ada daerah jarang yang tegas di antara segmen yang dapat dideteksi DBSCAN. Data Heart Disease berdimensi tinggi dengan banyak fitur kategorikal hasil one-hot, sehingga jarak antar-titik besar dan tidak terdapat daerah padat yang terpisah jelas; pada setiap ε yang diuji data berubah dari hampir seluruhnya noise menjadi satu cluster.

4.12.3 Kelebihan dan Kekurangan Setiap Algoritma

Tabel . Kelebihan dan kekurangan algoritma clustering

Algoritma	Kelebihan	Kekurangan
K-Means	Sederhana dan cepat; hasil mudah diinterpretasi lewat centroid; pada praktikum ini memberi nilai metrik terbaik atau hampir terbaik	Harus menentukan K di awal; sensitif terhadap inisialisasi dan outlier; cenderung membentuk cluster berbentuk bulat; setiap data dipaksa masuk satu cluster

Fuzzy C-Means	Memberi derajat keanggotaan sehingga data di perbatasan dapat dikenali; hasil mirip K-Means dengan informasi tambahan	Harus menentukan K dan parameter fuzziness m; iterasi lebih berat (Heart Disease: 350 iterasi, Mall Customers: 91 iterasi); tetap sensitif terhadap outlier
DBSCAN	Tidak perlu menentukan K; dapat menemukan cluster berbentuk sembarang; mendeteksi noise secara eksplisit	Sangat sensitif terhadap ε dan MinPts; kurang baik pada data tanpa celah kepadatan, kepadatan tidak seragam, atau berdimensi tinggi; sebagian data tidak mendapat cluster; metrik sulit dibandingkan karena noise dikeluarkan

4.12.4 Algoritma yang Memberikan Hasil Terbaik pada Setiap Dataset

Mall Customers. K-Means dan Fuzzy C-Means memberikan hasil terbaik dan hampir setara. K-Means unggul pada Silhouette dan CHI, sedangkan Fuzzy C-Means unggul pada DBI dengan selisih yang sangat kecil pada seluruh metrik. DBSCAN lebih rendah pada ketiga metrik di kedua ruang fitur dan menghasilkan segmentasi yang lebih sedikit (dua cluster dengan 14% noise). Jadi, DBSCAN tidak memberikan hasil yang lebih baik daripada K-Means pada dataset ini.

Heart Disease. K-Means dan Fuzzy C-Means kembali memberikan hasil terbaik dan hampir setara, masing-masing dengan dua cluster seimbang. Hasil DBSCAN tidak valid sehingga tidak dapat dinyatakan lebih baik meskipun nilai Silhouette dan DBI-nya tampak tinggi. Perlu dicatat bahwa Silhouette Score ketiga algoritma pada dataset ini rendah (sekitar 0,18 untuk K-Means dan Fuzzy C-Means), yang berarti struktur cluster pada data Heart Disease pada dasarnya lemah.

Secara keseluruhan, berdasarkan metrik internal, DBSCAN tidak memberikan hasil yang lebih baik daripada K-Means pada kedua dataset. Pemilihan akhir antara K-Means dan Fuzzy C-Means bergantung pada kebutuhan: K-Means cukup untuk pembagian tegas, sedangkan Fuzzy C-Means bermanfaat jika informasi derajat keanggotaan diperlukan.

BAB V
PENUTUP

5.1 Kesimpulan

Berdasarkan implementasi dan analisis perbandingan algoritma K-Means, Fuzzy C-Means (FCM), dan DBSCAN pada dataset Heart Disease dan Mall Customers, diperoleh kesimpulan sebagai berikut.

Ketiga algoritma berhasil diimplementasikan pada kedua dataset. K-Means dan Fuzzy C-Means dijalankan pada seluruh data dengan K = 4 untuk Mall Customers dan K = 2 untuk Heart Disease (FCM dengan fuzziness m = 2). DBSCAN dijalankan menggunakan grid search parameter ε dan MinPts, yaitu 162 kombinasi pada Mall Customers dan 328 kombinasi pada Heart Disease. Kualitas hasil dinilai dengan metrik internal (Silhouette Score, Davies-Bouldin Index, dan Calinski-Harabasz Index) karena clustering tidak memiliki label kebenaran sehingga tidak dikenal akurasi.

K-Means dan Fuzzy C-Means menghasilkan pengelompokan yang hampir identik. Nilai Adjusted Rand Index (ARI) antara keduanya sebesar 0,932 pada Mall Customers dan 0,953 pada Heart Disease. Hal ini wajar karena keduanya berbasis centroid dan jarak Euclidean; perbedaannya hanya pada keanggotaan, yaitu FCM memberikan derajat keanggotaan, sedangkan K-Means memberikan keanggotaan tegas.

DBSCAN pada Mall Customers menghasilkan dua cluster dan 14,00% noise, tetapi kualitasnya lebih rendah. Dengan parameter terpilih ε = 0,60 dan MinPts = 5 (hanya dua dari 162 kombinasi yang memenuhi seluruh kriteria), terbentuk Cluster 0 (137 pelanggan, 68,50%) yang mewakili pelanggan berusia menengah dengan pendapatan dan skor belanja menengah, serta Cluster 1 (35 pelanggan, 17,50%) yang mewakili pelanggan muda dengan pendapatan dan skor belanja tinggi. Sebanyak 28 pelanggan menjadi noise. Silhouette Score sebesar 0,2730, DBI sebesar 1,0204, dan CHI sebesar 54,4214 pada ruang fitur numerik, lebih lemah daripada K-Means (0,4047; 0,9335; 125,3909) dan Fuzzy C-Means (0,4024; 0,9218; 123,5323). Pola yang sama muncul pada ruang fitur numerik dan one-hot Gender serta pada subset 172 data non-noise yang sama.

DBSCAN pada Heart Disease tidak menghasilkan segmentasi yang valid. Tidak ada satu pun dari 328 kombinasi parameter yang memenuhi seluruh kriteria. Pada ε kecil hampir seluruh data menjadi noise (91,94% pada ε = 1,0), sedangkan pada ε besar seluruh data menyatu menjadi satu cluster. Kombinasi cadangan ε = 2,6 dan MinPts = 4 menghasilkan cluster berukuran 906 dan 4 pasien serta 8 noise, sehingga cluster terkecilnya hanya 0,44% data. Nilai Silhouette (0,3575) dan DBI (0,8277) yang tampak baik disebabkan oleh empat pasien berkolesterol sangat tinggi yang terpisah jauh dari cluster utama, sehingga tidak dapat dipercaya sebagai indikator kualitas. ARI DBSCAN terhadap K-Means maupun FCM sebesar 0,000.

K-Means dan Fuzzy C-Means memberikan hasil terbaik pada kedua dataset, dengan selisih yang sangat kecil. Pada Mall Customers, K-Means unggul pada

Silhouette (0,3195) dan CHI (85,1485), sedangkan FCM unggul pada DBI (1,1656). Pada Heart Disease, K-Means unggul pada DBI (2,0093) dan CHI (210,7287), sedangkan FCM unggul tipis pada Silhouette (0,1755). Dalam rekapitulasi metrik yang dimenangkan di antara hasil yang valid, K-Means memperoleh dua metrik dan FCM satu metrik pada masing-masing dataset, sedangkan DBSCAN tidak memenangkan satu pun metrik.

Penyebab DBSCAN kurang sesuai terletak pada struktur data. Pada Mall Customers, segmen-segmen pelanggan saling berdekatan sehingga tidak ada daerah jarang yang tegas di antara segmen untuk dideteksi DBSCAN. Pada Heart Disease, data berdimensi tinggi (21 fitur, termasuk hasil one-hot) sehingga jarak antar-titik besar dan tidak ada daerah padat yang terpisah jelas. Selain itu, DBSCAN sangat sensitif terhadap pemilihan ε dan MinPts.

Struktur cluster pada data Heart Disease pada dasarnya lemah. Silhouette Score K-Means dan Fuzzy C-Means hanya sekitar 0,18, sehingga dua cluster yang terbentuk sebaiknya dipandang sebagai pengelompokan awal, bukan segmen yang tegas.

Pemilihan akhir bergantung pada kebutuhan. Berdasarkan metrik internal, DBSCAN tidak memberikan hasil yang lebih baik daripada K-Means pada kedua dataset. K-Means cukup digunakan jika diperlukan pembagian tegas dengan interpretasi yang sederhana melalui centroid, sedangkan Fuzzy C-Means bermanfaat jika informasi derajat keanggotaan diperlukan, misalnya untuk mengenali data di perbatasan antar-cluster. DBSCAN lebih tepat digunakan untuk mengidentifikasi noise atau outlier, dan paling sesuai pada data yang memiliki celah kepadatan yang jelas.

5.2 Saran

Berdasarkan hasil dan keterbatasan yang ditemukan, saran untuk pengembangan selanjutnya adalah sebagai berikut.

1. Mengurangi dimensi sebelum menjalankan DBSCAN pada Heart Disease. Seleksi fitur atau reduksi dimensi (misalnya PCA sebagai masukan clustering, bukan hanya untuk visualisasi) dapat mengurangi dampak curse of dimensionality sehingga daerah padat lebih mudah dikenali.
2. Menggunakan pendekatan yang sesuai untuk data campuran numerik dan kategorikal. Algoritma atau ukuran jarak yang dirancang untuk data campuran, seperti K-Prototypes atau jarak Gower, dapat dicoba agar fitur kategorikal tidak mendistorsi jarak Euclidean seperti pada one-hot encoding.
3. Mencoba varian berbasis kepadatan yang lebih fleksibel. HDBSCAN atau OPTICS dapat menangani cluster dengan kepadatan yang berbeda-beda dan tidak bergantung pada satu nilai ε, sehingga berpotensi lebih baik daripada DBSCAN pada kedua dataset.
4. Menangani outlier dan nilai ekstrem sebelum clustering. Nilai ekstrem, terutama kolesterol pada Heart Disease, terbukti membentuk cluster kecil dan noise.

Penanganan outlier yang lebih terkontrol, atau analisis dengan dan tanpa outlier, dapat membantu menilai pengaruhnya terhadap hasil.

5. Memperhalus pencarian parameter dan melengkapi evaluasi. Grid search ε dengan langkah yang lebih halus serta variasi jumlah cluster (K) yang lebih luas pada K-Means dan Fuzzy C-Means dapat memberi hasil yang lebih teliti. Evaluasi sebaiknya ditambah dengan uji stabilitas hasil (misalnya dengan beberapa inisialisasi acak) dan validasi dari sisi domain.
6. Menambah validasi eksternal dan interpretasi domain. Karena metrik internal tidak menjamin kebermaknaan cluster, hasil clustering sebaiknya ditinjau oleh pihak yang memahami domain (tenaga medis untuk Heart Disease dan pihak pemasaran untuk Mall Customers). Pada Heart Disease, proporsi pasien penyakit jantung per cluster dapat dimanfaatkan sebagai bahan interpretasi, bukan sebagai masukan clustering.
7. Memperluas fitur dan cakupan data. Penambahan fitur perilaku pelanggan pada Mall Customers dan penggunaan dataset yang lebih besar atau lebih beragam dapat memperkaya segmentasi dan menguji apakah kesimpulan perbandingan algoritma tetap berlaku.

DAFTAR PUSTAKA

Choudhary, S. Gold price prediction [Dataset]. Kaggle. https://www.kaggle.com/datasets/suryanachoudhary/gold-price-prediction (diakses: 8 November 2026).

Pedregosa, F., dkk. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

LAMPIRAN

A. Pembagian Tugas Anggota Kelompok

Tabel A.1 Pembagian Tugas Anggota Kelompok

No.	Anggota	Tanggung Jawab	Output
1	ISA	Memeriksa struktur dan karakteristik dataset Heart Disease dan Mall Customers; melakukan preprocessing data, meliputi pemeriksaan missing value, duplikasi, nilai tidak valid, identifikasi outlier, pemilihan fitur, encoding, dan standardisasi; mengimplementasikan algoritma K-Means pada kedua dataset; menentukan jumlah cluster (K), menjalankan proses clustering, menyimpan label cluster, serta melakukan evaluasi dan pemeriksaan hasil program.	Dataset hasil preprocessing (.csv), kode preprocessing dan K-Means (.py), hasil clustering, label cluster, tabel evaluasi, visualisasi K-Means, screenshot source code dan output, serta dokumentasi preprocessing.
2	RYAN	Mengimplementasikan algoritma Fuzzy C-Means (FCM) menggunakan Python pada dataset Heart Disease dan Mall Customers; menentukan jumlah cluster dan parameter FCM, menjalankan proses clustering, menghasilkan derajat keanggotaan dan label cluster, serta melakukan evaluasi dan pemeriksaan hasil program.	Program Fuzzy C-Means (.py), hasil derajat keanggotaan, label cluster, tabel evaluasi, visualisasi FCM, screenshot source code dan output, serta dokumentasi implementasi FCM.
3	ARYA	Mengimplementasikan algoritma DBSCAN menggunakan Python pada dataset Heart Disease dan Mall Customers; menentukan parameter epsilon (ε) dan MinPts, menjalankan proses clustering, mengidentifikasi cluster dan noise point, serta melakukan evaluasi dan pemeriksaan hasil program. Mengintegrasikan visualisasi perbandingan hasil clustering dan membantu analisis karakteristik cluster.	Program DBSCAN (.py), hasil clustering, identifikasi noise point, tabel evaluasi, visualisasi DBSCAN dan perbandingan algoritma, screenshot source code dan output, serta dokumentasi implementasi DBSCAN.

Tabel A.2 Pembagian Tahapan Pengerjaan

Tahap	Penanggung Jawab	Hasil yang Diintegrasikan
Pemilihan dan pemeriksaan dataset	ISA	Dataset Heart Disease dan Mall Customers, informasi struktur

		dataset, karakteristik data, serta hasil pemeriksaan awal.
Preprocessing dan penentuan fitur	ISA	Dataset siap digunakan dalam proses clustering, hasil encoding dan standardisasi, serta matriks fitur untuk kedua dataset.
Implementasi algoritma K-Means	ISA	Program K-Means, penentuan jumlah cluster (K), label cluster, hasil clustering, dan evaluasi model.
Implementasi algoritma Fuzzy C-Means	RYAN	Program FCM, penentuan parameter, derajat keanggotaan, label cluster, hasil clustering, dan evaluasi model.
Implementasi algoritma DBSCAN	ARYA	Program DBSCAN, penentuan parameter epsilon dan MinPts, hasil clustering, identifikasi noise point, dan evaluasi model.
Evaluasi dan visualisasi hasil clustering	ISA, RYAN, ARYA	Grafik, tabel evaluasi Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz Index, distribusi anggota cluster, serta visualisasi hasil ketiga algoritma.
Analisis dan perbandingan hasil clustering	Seluruh anggota	Perbandingan hasil K-Means, FCM, dan DBSCAN pada dataset Heart Disease dan Mall Customers, termasuk interpretasi karakteristik cluster dan analisis kelebihan serta kekurangan algoritma.

B. Repository dan Struktur Project

Repository: https://github.com/roisatul812/TM10_K6_ML-Prak.git

Folder / File	Isi
database/	Dataset Multiclass-Diabetes-Dataset.csv

code/01_preprocessing_heart.py	Preprocessing
code/02_preprocessing_mall.py	Preprocessing
code/03_kmeans_heart.py	K-Prototypes Dataset Heart
code/04_kmeans_mall.py	K-Prototypes Dataset Mall
code/05_fuzzy_cmeans_heart.py	Fuzzy CMeans Dataset Heart
code/06_fuzzy_cmeans_mall.py	Fuzzy CMeans Dataset Mall
code/07_dbscan_heart.py	DBScan Dataset Heart
code/08_dbscan_mall.py	DBScan Dataset Mall
code/09_compare_clustering.py	Comparison antar metode
output/	Hasil preprocessing, K-Means, Fuzzy CMeans, DBScan, Evaluasi, dan Visualisasi
requirements.txt	Daftar library

Menjalankan antarmuka: pip install -r requirements.txt, lalu cd app dan streamlit run app.py.