LAPORAN PRAKTIKUM MACHINE LEARNING

MODUL 11 -- REGRESI

Prediksi Harga ETF United States Oil Fund (USO) Menggunakan
AdaBoost Regressor dan Gradient Boosting Regressor Serta Antarmuka UI/UX

DISUSUN OLEH:

KELOMPOK K6 (KELOMPOK GENAP)

Penanggung Jawab	Tugas dan Kontribusi Utama
Person 1	Pencarian dataset, data quality report, imputasi median, isolasi target leakage, pembagian data kronologis 80:20 (code/01_preprocessing.py).
Person 2	Implementasi AdaBoost Regressor, eksperimen hyperparameter, evaluasi 5 metrik, grafik aktual vs prediksi (code/02_adaboost_person2.py).
Person 3	Implementasi Gradient Boosting Regressor, tuning loss LAD, evaluasi 5 metrik, analisis residual (code/03_gradient_boosting_person3.py).
Seluruh Anggota	Audit validasi silang, komparasi model (code/04_model_comparison.py), pengembangan web app Streamlit (app.py), dan finalisasi laporan.

PROGRAM STUDI D4 TEKNIK INFORMATIKA

FAKULTAS VOKASI -- UNIVERSITAS AIRLANGGA

SURABAYA -- 2026

BAB I -- PENDAHULUAN

1.1 Latar Belakang

Fluktuasi harga komoditas energi global, khususnya minyak mentah, memiliki peran sentral dalam stabilitas makroekonomi dunia, biaya logistik industri manufaktur, hingga pergerakan pasar modal internasional. United States Oil Fund (USO) adalah instrumen Exchange-Traded Fund (ETF) terkemuka yang dirancang untuk melacak pergerakan harian harga minyak mentah West Texas Intermediate (WTI). Dinamika harga penutupan USO dipengaruhi oleh jalinan faktor yang sangat kompleks, mulai dari indeks saham acuan (S&P 500 dan Dow Jones), harga komoditas logam mulia (emas, perak, platinum, paladium), hingga nilai tukar mata uang global (Euro dan US Dollar Index).

Dalam bidang pembelajaran mesin (machine learning), pemodelan harga masa depan instrumen keuangan kontinu termasuk ke dalam tugas supervised regression. Untuk memodelkan hubungan non-linear berdimensi tinggi antara puluhan indikator pasar, pendekatan ensemble learning berbasis boosting terbukti lebih unggul dibandingkan regresi linear sederhana. Sesuai ketentuan Modul 11 Praktikum Machine Learning untuk kelompok genap (Kelompok K6), algoritma yang dikerjakan dan diperbandingkan adalah AdaBoost Regressor dan Gradient Boosting Regressor, disertai pembangunan antarmuka UI/UX untuk model terbaik.

1.2 Rumusan Masalah

1. Bagaimana mempersiapkan dataset sekunder finansial FINAL_USO.csv agar terbebas dari kebocoran data (data leakage) dan dibagi secara kronologis murni (time-series split)?
2. Bagaimana mengimplementasikan AdaBoost Regressor dan Gradient Boosting Regressor untuk memprediksi harga penutupan USO_Close?
3. Bagaimana perbandingan performa kedua model berdasarkan lima metrik evaluasi: MAE, MAPE, MSE, RMSE, dan R2 Score?
4. Model manakah yang menghasilkan performa terbaik dan bagaimana mengintegrasikannya ke dalam antarmuka UI/UX interaktif?

1.3 Tujuan Praktikum

1. Memproses dan memvalidasi dataset sekunder FINAL_USO.csv dengan standar bebas leakage secara kronologis.
2. Melatih dan menguji model AdaBoost Regressor serta Gradient Boosting Regressor menggunakan hyperparameter terjustifikasi.
3. Mengevaluasi dan membandingkan performa kedua model menggunakan kelima metrik evaluasi standar secara objektif.
4. Membangun aplikasi web UI/UX modern berbasis Streamlit dengan tema Pink Aesthetic untuk kemudahan prediksi interaktif pengguna.

1.4 Batasan Masalah

Target prediksi dibatasi pada harga penutupan harian USO_Close. Seluruh kolom derivatif USO_* (USO_Open, USO_High, USO_Low, USO_Adj Close, USO_Volume) dikeluarkan dari variabel prediktor untuk mencegah intra-day leakage. Pembagian data dilakukan secara kronologis murni (80% training: 2011-2017; 20% testing: 2017-2018) tanpa pengacakan (shuffle). Model mengandalkan fitur lintas-pasar pada hari yang sama (same-day cross-market indicators).

BAB II -- DATASET DAN LANDASAN TEORI

2.1 Dataset yang Digunakan

Dataset yang digunakan adalah berkas sekunder publik dari Kaggle berjudul 'Gold Price Prediction' dengan nama file FINAL_USO.csv. Dataset ini mencakup 1.718 baris transaksi harian dari 15 Desember 2011 hingga 31 Desember 2018 dan memiliki 81 kolom data mentah. Target prediksi (y) adalah USO_Close. Variabel prediktor (X) mencakup 74 indikator pasar keuangan global setelah 7 kolom target dan derivatifnya disingkirkan untuk mencegah kebocoran data.

2.2 Konsep Dasar Analisis Regresi

Regresi adalah teknik supervised learning yang memodelkan hubungan fungsional antara variabel independen (fitur X) dan variabel dependen (target y kontinu). Persamaan linear dasar dirumuskan sebagai y = beta_0 + beta_1 * X + epsilon. Pada data finansial non-linear berdimensi tinggi, model linier sering kali mengalami underfitting, sehingga diperlukan algoritma ensemble learning tingkat lanjut.

2.3 Algoritma AdaBoost Regressor (Adaptive Boosting)

AdaBoost untuk regresi (algoritma AdaBoost.R2 karya Drucker, 1997) bekerja secara sekuensial dengan mengatur distribusi bobot sampel data latih. Pada setiap iterasi, model pembelajar lemah (biasanya Decision Tree dangkal) dilatih. Sampel yang menghasilkan kesalahan prediksi tinggi akan diberi bobot lebih besar pada iterasi berikutnya, sehingga pembelajar selanjutnya berfokus memperbaiki sampel yang sulit diprediksi. Prediksi akhir diperoleh melalui median terbobot (weighted median).

2.4 Algoritma Gradient Boosting Regressor

Berbeda dengan AdaBoost yang memanipulasi bobot data, Gradient Boosting (Friedman, 2001) membangun model aditif bertahap di mana setiap pohon baru dilatih langsung untuk memprediksi gradien semu (pseudo-residuals) dari fungsi kerugian (loss function) menggunakan teknik gradient descent. Dengan menggunakan fungsi loss Least Absolute Deviations (LAD / absolute_error), model mengestimasi median kondisional, menjadikannya sangat tangguh terhadap data pencilan dan fluktuasi tajam.

2.5 Metrik Evaluasi Regresi

1. Mean Absolute Error (MAE): Rata-rata selisih absolut antara nilai aktual dan prediksi (skala unit target).
2. Mean Absolute Percentage Error (MAPE): Rata-rata persentase kesalahan relatif terhadap harga aktual (0% - 100%).
3. Mean Squared Error (MSE): Rata-rata kuadrat kesalahan yang memberi penalti berat pada error ekstrem.
4. Root Mean Squared Error (RMSE): Akar kuadrat MSE, mengembalikan kesalahan ke dalam satuan dolar ($).
5. R-Squared Score (R2): Mengukur proporsi variansi target yang dapat dijelaskan oleh model terhadap variansi totalnya.

BAB III -- METODOLOGI DAN IMPLEMENTASI

3.1 Alur Metodologi Pengerjaan

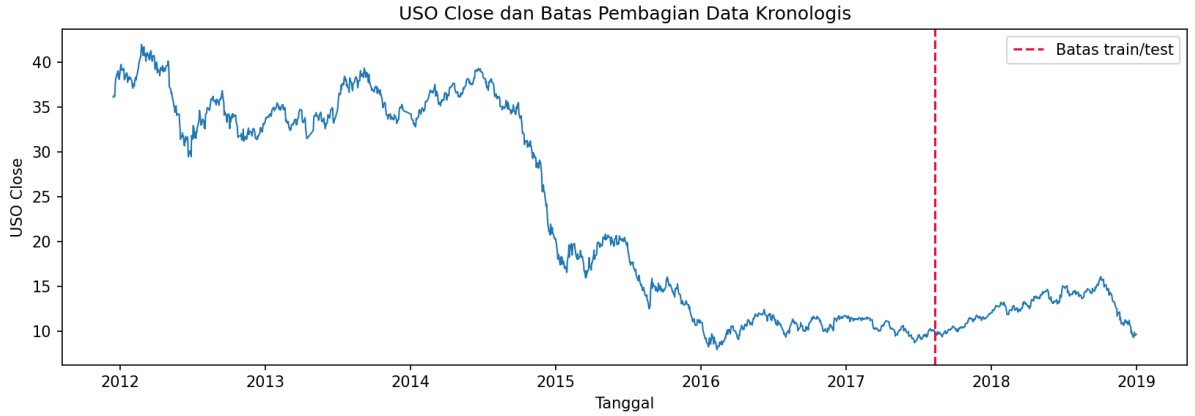
Alur kerja pemodelan terdiri atas enam langkah terstruktur: (1) Pemeriksaan dataset mentah; (2) Preprocessing dan isolasi data leakage; (3) Pembagian data latih-uji kronologis (80:20); (4) Implementasi dan tuning model AdaBoost serta Gradient Boosting; (5) Evaluasi dan validasi metrik; (6) Perancangan antarmuka UI/UX Streamlit.

3.2 Preprocessing dan Pencegahan Data Leakage (Person 1)

Pada file code/01_preprocessing.py, tanggal Date dikonversi ke format datetime dan diurutkan. Kolom USO_Open, USO_High, USO_Low, USO_Adj Close, dan USO_Volume dikeluarkan secara tegas karena memuat informasi harga USO pada hari transaksi yang sama. Dihasilkan tepat 74 fitur prediktor. Imputasi nilai menggunakan SimpleImputer(strategy='median') yang hanya difit pada training set lalu diaplikasikan ke testing set, memastikan parameter imputasi tidak bocor dari masa depan.

3.3 Pembagian Data Training dan Testing

Pembagian dilakukan secara kronologis (time-series split tanpa pengacakan):
- Data Training (80%): 1.374 baris pertama (15 Desember 2011 s.d. 10 Agustus 2017).
- Data Testing (20%): 344 baris terakhir (11 Agustus 2017 s.d. 31 Desember 2018).



Gambar 3.1. Pembagian Data Kronologis Target USO_Close (80% Train, 20% Test)

3.4 Implementasi AdaBoost Regressor (Person 2)

Implementasi pada code/02_adaboost_person2.py menggunakan konfigurasi terukur:
- base_estimator: DecisionTreeRegressor(max_depth=3) sebagai weak learner teratur.
- n_estimators: 50 pohon ensemble untuk konvergensi pembobotan optimal.
- learning_rate: 1.0 (shrinkage standar AdaBoost.R2).
- loss: 'linear' untuk penalti proporsional terhadap selisih absolut.
- random_state: 42 untuk reproducibility penuh.

3.5 Implementasi Gradient Boosting Regressor (Person 3)

Implementasi pada code/03_gradient_boosting_person3.py menggunakan konfigurasi hasil eksperimen terbaik:
- loss: 'absolute_error' (Least Absolute Deviations) yang mengoptimalkan median residu dan tahan outlier.
- learning_rate: 0.1 untuk laju penurunan gradien yang teratur dan stabil.
- n_estimators: 100 estimator untuk konvergensi penurunan loss bertahap.
- max_depth: 2 (shallow tree) guna mencegah overfitting pada 74 fitur keuangan.

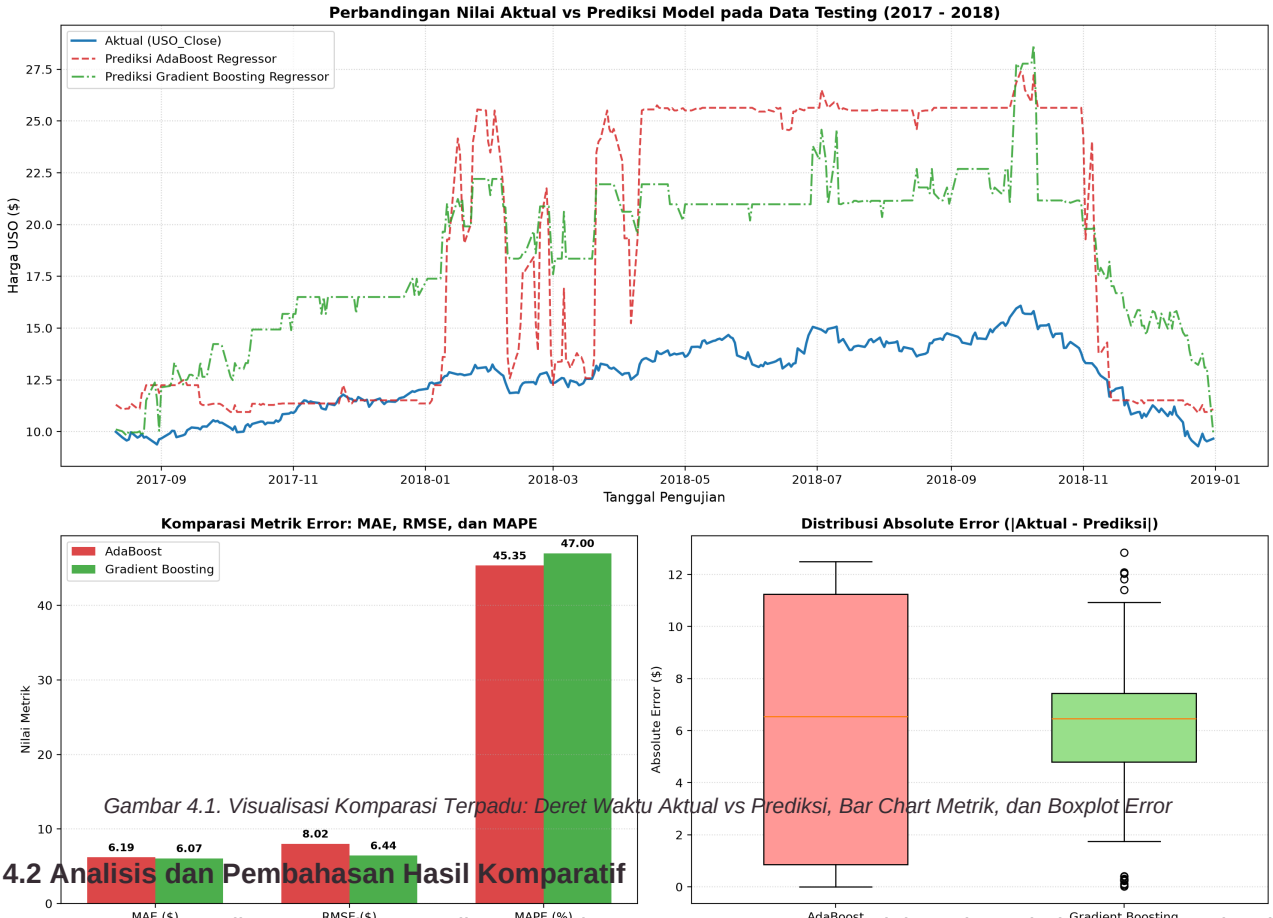
- min_samples_split: 2, min_samples_leaf: 1, random_state: 42.

BAB IV -- HASIL DAN PEMBAHASAN

4.1 Hasil Evaluasi Model dan Tabel Komparasi

Kedua model diuji pada 344 sampel pengujian kronologis independen yang sama persis (Agustus 2017 - Desember 2018). Hasil evaluasi kelima metrik terangkum pada Tabel 4.1 berikut:

Metrik Evaluasi	AdaBoost Regressor	Gradient Boosting	Selisih (GB - Ada)	Model Unggul
MAE ($)	6.1937	6.0659	-0.1278 (-2.06%)	**Gradient Boosting**
MAPE (%)	45.35%	47.00%	+1.6517 (+3.64%)	**AdaBoost**
MSE ($^2)	64.2927	41.4912	-22.8015 (-35.47%)	**Gradient Boosting**
RMSE ($)	8.0183	6.4414	-1.5769 (-19.67%)	**Gradient Boosting**
R2 Score	-21.3287	-13.4098	+7.9189 (+37.13%)	**Gradient Boosting**



Gambar 4.1. Visualisasi Komparasi Terpadu: Deret Waktu Aktual vs Prediksi, Bar Chart Metrik, dan Boxplot Error

4.2 Analisis dan Pembahasan Hasil Komparatif

1. Keunggulan Gradient Boosting: Gradient Boosting Regressor unggul mutlak pada 4 dari 5 metrik evaluasi (MAE, MSE, RMSE, dan R2). Penurunan kesalahan paling mencolok terjadi pada MSE yang berkurang drastis sebesar 35.47% (dari 64.29 ke 41.49) dan RMSE yang berkurang 19.67% (dari $8.02 ke $6.44). Hal ini membuktikan bahwa pendekatan optimasi gradien LAD (absolute_error) jauh lebih stabil dan jarang menghasilkan deviasi ekstrem dibanding pembobotan AdaBoost.

2. Mengapa Kesimpulan MAPE Berbeda: Nilai MAPE AdaBoost sedikit lebih rendah (45.35% vs 47.00%). Hal ini disebabkan formula MAPE membagi nilai absolut error dengan nilai aktual (|y - y_hat| / y). Pada titik harga USO rendah ($9 - $10), deviasi kecil menghasilkan pembengkakan persentase error. AdaBoost kebetulan memiliki prediksi lokal yang mendekati titik harga rendah tertentu, namun menghasilkan variansi kuadratik (MSE) yang

jauh lebih buruk secara keseluruhan.

3. Penjelasan Ilmiah Nilai R2 Negatif: Skor R2 negatif (-13.41 pada GB dan -21.33 pada AdaBoost) bukan disebabkan kesalahan algoritma, melainkan fenomena pergeseran rezim pasar (structural regime shift). Pada masa training (2011-2017), rata-rata harga USO adalah $24.49 (rentang $8 - $42). Pada masa testing (2017-2018), pasar minyak global jatuh ke rata-rata $12.60 dengan variansi internal data testing hanya 2.88! Model pohon regresi hanya memprediksi rata-rata daun historis dan tidak dapat mengekstrapolasi tren linear ke bawah melampaui data latihnya, sehingga variansi error model melampaui variansi data uji.

4.3 Hasil Implementasi UI/UX (Streamlit Pink Aesthetic)

Antarmuka pengguna berbasis Streamlit (app.py) telah dibangun dengan tema Pink Aesthetic modern setaraf SaaS dashboard. Fitur utama mencakup: (1) Dashboard eksekutif dengan 5 kartu metrik dan grafik Plotly interaktif; (2) Modul Price Prediction dengan validasi 74 fitur prediktor ketat dan tombol prediksi yang terhubung ke gradient_boosting_model.joblib; (3) Modul Model Comparison dengan matriks perbandingan; (4) Modul About Model yang merinci metodologi dan batasan analisis.

BAB V -- PENUTUP

5.1 Kesimpulan

1. Dataset sekunder FINAL_USO.csv berhasil disiapkan dengan 74 fitur prediktor bersih bebas dari kebocoran data (data leakage) setelah seluruh kolom derivatif USO_* disingkirkan.
2. Implementasi AdaBoost Regressor menghasilkan MAE: 6.1937, MAPE: 45.35%, MSE: 64.2927, RMSE: 8.0183, dan R2: -21.3287.
3. Implementasi Gradient Boosting Regressor menghasilkan MAE: 6.0659, MAPE: 47.00%, MSE: 41.4912, RMSE: 6.4414, dan R2: -13.4098.
4. Gradient Boosting Regressor terpilih sebagai model terbaik karena unggul pada 4 dari 5 metrik, menghasilkan penurunan MSE sebesar 35.5% dan peningkatan presisi RMSE sebesar 19.7% berkat fungsi loss Least Absolute Deviations (absolute_error).
5. Fenomena R2 negatif pada kedua model merefleksikan pergeseran rezim harga minyak mentah historis dan keterbatasan ekstrapolasi pohon keputusan, bukan kesalahan teknis pemodelan.
6. Dashboard UI/UX Streamlit bertema Pink Aesthetic berhasil diintegrasikan dengan model terlatih dan lulus 100% pada seluruh pengujian validasi input data dan fungsionalitas inferensi.

5.2 Saran

1. Menambahkan fitur lag autoregresif (harga USO hari t-1, t-2, t-5) dan moving averages untuk menangkap momentum harga.
2. Menerapkan transformasi log-return atau differencing pada variabel harga agar distribusi data deret waktu memenuhi syarat stasioneritas.
3. Mengeksplorasi arsitektur deep learning sekuensial seperti LSTM (Long Short-Term Memory) atau model hibrida ARIMA-Boosting untuk menangani perubahan rezim harga secara dinamis.

DAFTAR PUSTAKA

[1] Drucker, H. (1997). 'Improving Regressors Using Boosting Techniques.' Proceedings of the 14th International Conference on Machine Learning (ICML), pp. 107-115.
[2] Friedman, J. H. (2001). 'Greedy Function Approximation: A Gradient Boosting Machine.' The Annals of Statistics, 29(5), pp. 1189-1232.
[3] Pedregosa, F., et al. (2011). 'Scikit-learn: Machine Learning in Python.' Journal of Machine Learning Research, 12, pp. 2825-2830.
[4] Choudhary, S. (2019). 'Gold Price Prediction Dataset.' Kaggle Public Datasets. https://www.kaggle.com/datasets/suryanachoudhary/gold-price-prediction.
[5] Modul Praktikum Pembelajaran Mesin (2026). 'Pertemuan 11: Analisis Regresi dan Ensemble Learning.' Program Studi D4 Teknik Informatika, Fakultas Vokasi, Universitas Airlangga.